

Тема 1. ПРЕДМЕТ І ЗАВДАННЯ ПРИКЛАДНОЇ СТАТИСТИКИ. СТАТИСТИЧНІ РОЗПОДІЛИ ВИБІРКИ

- ПРЕДМЕТ І ЗАВДАННЯ ПРИКЛАДНОЇ СТАТИСТИКИ;
 - ЕТАПИ СТАТИСТИЧНОГО АНАЛІЗУ;
 - ГЕНЕРАЛЬНА І ВИБІРКОВА СУКУПНОСТІ;
 - СТАТИСТИЧНІ РОЗПОДІЛИ ВИБІРКИ. ЕМПІРИЧНА ФУНКЦІЯ СТАТИСТИЧНОГО РОЗПОДІЛУ. ПОЛІГОН. ГІСТОГРАМА
-

ПРЕДМЕТ І ЗАВДАННЯ ПРИКЛАДНОЇ СТАТИСТИКИ

Прикладна статистика — це розділ математики, що вивчає закономірності, характерні для масових явищ і статистичних сукупностей. Тобто вивчення й установлення закономірностей, яким підпорядковуються масові випадкові явища, є предметом статистики. Методологія статистики, застосовувана для обробки статистичних даних, результатів спостережень, даних реальних або штучно поставлених дослідів, базується на методах теорії ймовірностей.

Особливу роль відіграє вибірковий метод статистики, який широко використовується в управлінні, фінансах, маркетингу, організації виробництва тощо. Аналізуючи, здавалося б, випадкові явища, вдається встановити відповідні закономірності та зв'язки між ними, зробити прогнози їхнього розвитку, оцінити параметри, які характеризують ці явища. Наявність такої інформації дає змогу прийняти обґрунтовані рішення за умов невизначеності.

Класична статистика має на меті в основному розв'язання двох завдань.

Перше з них — це виявити й обґрунтувати способи збору та групування статистичних відомостей, одержаних у результаті спостережень за об'єктом дослідження або за результатами спеціально поставлених експериментів.

Так, наприклад, організація збору інформації під час екзитполу може суттєво вплинути на його результати і привести до грубих помилок.

Друге завдання статистики полягає в розробленні методів аналізу статистичних даних, котре ґрунтується на теоремах і методах теорії ймовірностей. Зокрема, закон великих чисел, теорема Чебишова дають можливість обґрунтувати вибірковий метод.

Доречно виокремити завдання статистики:

- перевірка статистичних гіпотез про закон невідомого розподілу або про значення параметрів відомого розподілу;***
- побудова регресійних залежностей і оцінки рівня значущості параметрів цих залежностей;***
- визначення кількості необхідних випробувань у процесі планування експерименту і т. ін.***

Підсумовуючи, зазначимо, що ключовим завданням прикладної статистики є створення і обґрунтування методів збору й обробки статистичних даних для одержання наукових та практичних висновків і рекомендацій з метою дальшого їх використання для аналізу закономірностей у масових випадкових явищах.

Чотири етапи статистичного аналізу

Прикладна статистика – це мистецтво і наука збору, обробки даних і аналізу отриманих результатів з метою прийняття коректних обґрунтованих рішень технічного, ділового, політичного, персонального або іншого характеру.

Статистичні методи необхідно розглядати як важливу трудомістку частину процесу прийняття рішень, яка дає можливість приймати обґрунтовані тактичні і стратегічні рішення. Ці методи ґрунтуються на знаннях та інтуїції фахівців і глибокому аналізі наявної інформації.

Коректне використання статистичних методів надає значні переваги практично в усіх напрямках людської діяльності: в конкуренції за підвищення якості та зростання продаж нової продукції, дає можливість отримати високоякісні оцінки прогнозів, обґрунтувати мікро- і макроекономічні рішення, а також рішення стосовно раціонального ведення домашнього господарства і розв'язати багато інших задач, у тому числі персонального характеру.

Задачі, які розв'язують методами прикладної статистики

I Класичні задачі прикладної статистики

Це базові напрямки, які формували статистику як прикладну науку протягом XX століття:

- ☐ **Управління якістю :** Статистичний контроль процесів на виробництві для мінімізації браку.
- ☐ **Аналіз ринку та попиту:** Прогнозування обсягів продажу товарів та аналіз споживчого кошика.
- ☐ **Біостатистика та медицина:** Перевірка ефективності нових ліків за допомогою клінічних випробувань (порівняння контрольної та експериментальної груп).
- ☐ **Економічне прогнозування:** Аналіз динаміки інфляції, курсу валют та ВВП на державному рівні.
- ☐ **Психологія та соціологія:** Обробка результатів тестів та опитувань для виявлення закономірностей у поведінці великих груп людей.
- ☐ **Планування експерименту:** Розрахунок мінімально необхідної кількості випробувань для отримання достовірного результату в наукових дослідженнях.

II. Задачі в IT та розробці ПЗ

Тут статистика використовується для оптимізації продуктів та систем:

- ☐ **A/B тестування інтерфейсів:** Статистичне порівняння двох версій дизайну (наприклад, колір кнопки), щоб зрозуміти, яка з них приносить більше конверсій.
- ☐ **Аналіз надійності (Site Reliability Engineering):** Розрахунок метрик SLA, SLO та аналіз середнього часу між збоями (MTBF) серверів.
- ☐ **Оптимізація алгоритмів пошуку та рекомендацій:** Використання статистики для підбору контенту, який з найбільшою імовірністю зацікавить користувача.
- ☐ **Аналіз продуктивності (Benchmarking):** Статистичне порівняння швидкодії коду до та після оптимізації з урахуванням випадкових похибок ОС.

III. Спеціалізовані задачі в Кібербезпеці

Це те, що безпосередньо стосується спеціальності 125 Кібербезпека. Задачі, які з'явилися або стали критичними зовсім нещодавно:

❑ Поведінкова аналітика (User and Entity Behavior Analytics - UEBA):

- *Задача:* Побудова статистичного "baseline" (нормальної поведінки) користувача.
- *Приклад:* Якщо адмін зазвичай заходить о 9:00 з Києва, а сьогодні зайшов о 3:00 ночі з Лагосу — статистика сигналізує про аномалію.

❑ Боротьба з генеративним ШІ (Deepfake Detection):

- *Задача:* Статистичний аналіз цифрових шумів та мікро-затримок у відео/аудіо.
- *Приклад:* Штучне відео має інший статистичний розподіл пікселів у певних частотних діапазонах, ніж реальне.

❑ Аналіз Zero-Day вразливостей (Threat Hunting):

- *Задача:* Пошук невідомих атак через статистичні аномалії в системних викликах.
- *Приклад:* Використання методів авторегресії для виявлення нетипового споживання пам'яті процесом, що може бути ознакою експлуатації вразливості.

❑ Детектування ботнетів та AI-ботів:

- *Задача:* Статистичний аналіз таймінгів мережевих пакетів (Jitter).
- *Приклад:* Людина натискає клавіші з випадковими паузами, бот — з математично вивіреною періодичністю, яку легко виявити статистично.

❑ Криптографічний аудит:

- *Задача:* Перевірка випадковості послідовностей (NIST Statistical Test Suite).
- *Приклад:* Якщо генератор випадкових чисел видає послідовність, що не проходить тести на ентропію, шифрування стає вразливим до зламу.

❑ Кібер-страхування та Risk Scoring:

- *Задача:* Розрахунок імовірності успішної атаки на конкретне підприємство.
- *Приклад:* Використання формули Байєса для оновлення оцінки ризику при виникненні нових загроз у світі.

❑ Аналіз витоків даних (DLP):

- *Задача:* Виявлення прихованих каналів витоку інформації через аналіз об'ємів трафіку.
- *Приклад:* Статистика показує, що об'єм вихідного трафіку на зашифрований DNS-сервер зріс на 200% — це може бути витік даних.

На **початковій стадії** виконання статистичного аналізу, власне даних для аналізу, як правило, немає або ще навіть не прийнято рішення стосовно того, які дані необхідно аналізувати. Це питання вирішують на етапі *планування збору даних* таким чином, щоб отримати дійсно корисні, максимально повні та інформативні дані.

На **другому етапі** *висувають гіпотези* та виконують *попередню обробку* і *дослідження* даних.

Третій етап – *оцінювання необхідних статистичних параметрів та інших невідомих величин*, параметрів математичних моделей і т. ін.

На останньому, **четвертому, етапі** виконується *перевірка висунутих гіпотез* – дані використовують для прийняття рішення щодо відповідності апріорно висунутого припущення дійсній ситуації. Розглянемо згадані етапи статистичного аналізу докладніше.

Чотири етапи статистичного аналізу даних

1. Планування експерименту і збір даних. Результат – корисні інформативні та повні дані стосовно функціонування (протікання) процесу.
2. Попередня обробка та дослідження даних, формулювання гіпотез стосовно типів розподілів, значущості оцінок, якості (адекватності) моделей, настання можливих ситуацій і т. ін.
3. Оцінювання параметрів математичних і статистичних моделей. Результат – адекватні процесу математичні і статистичні моделі, що підтверджується відповідними статистичними параметрами якості.
4. Перевірка раніше сформульованих гіпотез, прийняття рішень стосовно управління процесами.

Розглянемо деякі терміни, що стосуються статистичних даних і моделей, які оцінюються на їх основі.

Математичні моделі, які ми будемо розглядати, це моделі у вигляді рівнянь різних типів: диференціальних різницевих, алгебраїчних.

Статистичні моделі – це моделі у формі розподілів ймовірностей випадкових величин.

Статистичні дані у формі вимірів, прив'язаних до конкретних моментів часу, тобто *часових рядів* розглядаються у прикладній статистиці як випадкові процеси з детермінованими складовими:

$$y(k) = \text{константа} + \text{детермінована складова} + \text{випадкова складова}.$$

Детермінована складова процесу надає можливість будувати регресійні моделі та моделі деяких інших типів. Так, наявність автокореляції часового ряду дає можливість будувати авторегресійні моделі, порядок яких визначається за допомогою автокореляційної і часткової автокореляційної функцій.

Статистичні дані у формі вимірів, які стосуються деякого вибраного моменту часу (наприклад, конкретного місяця року), називають *часовими перерізами*.

Поява випадкової складової у вимірах змінних досліджуваних процесів зумовлена такими причинами:

- наявність випадкових збурень, які, як правило, неможливо виміряти;
- некоректне формування структури моделі: в праву частину рівняння можуть бути введені “зайві” змінні, тобто такі, що формально корельовані із залежною змінною, але фактично на неї не впливають або впливають дуже слабо;
- можливо, що у праву частину рівняння помилково не введені незалежні змінні, які фактично мають досить сильний вплив на залежну;
- похибки обчислень, які завжди виникають при оцінюванні параметрів моделей.

ГЕНЕРАЛЬНА І ВИБІРКОВА СУКУПНОСТІ

Генеральна сукупність – це вся множина статистичних одиниць, якісні або кількісні характеристики котрих потрібно дослідити.

На практиці найчастіше розглядаються скінченні генеральні сукупності. Кількість статистичних одиниць у них є скінченною величиною, хоч і може бути достатньо великою. Проте якщо кількість одиниць генеральної сукупності велика, з метою спрощення обчислень або полегшення теоретичних висновків припускається, що кількість одиниць сукупності нескінченна або прямує до нескінченності.

Розглянуте припущення дозволяє переносити результати, одержані в теоремах теорії ймовірностей, які називаються законами великих чисел, на скінченні генеральні сукупності. Основним результатом цих теорем є те, що за виконання певних умов сумарна поведінка достатньо великої кількості випадкових величин утрачає випадковий характер і стає практично закономірною.

Вибіркова сукупність – це скінченна множина статистичних одиниць, випадково вибраних з генеральної сукупності.

Звичайно, точніші результати статистичного дослідження можна одержати за дослідження генеральної сукупності. Але в цьому разі можуть виникнути проблеми, пов'язані з великою кількістю одиниць генеральної сукупності або зі знищенням статистичної одиниці, або з великими матеріальними витратами і т. ін.

Скажімо, з метою дослідження якості завезеного на елеватор зерна неможливо перевірити кожну зернину, що є в кузові автомобіля. Тому в таких випадках утворюють вибірку сукупність, до складу якої входить скінченна кількість (як правило, не дуже велика) випадково вибраних одиниць з генеральної сукупності.

У прикладі з якістю зерна навантаження вибирають певну кількість проб з усієї маси зерна, утворюючи вибірку сукупність.

Спираючись на теорему Чебишова, можна стверджувати, що на основі обстеження відносно невеликої випадкової вибірки, одержані результати й закономірності можна переносити з відповідною точністю на всю генеральну сукупність. У цьому полягає сутність вибіркового методу статистики.

Кількість статистичних одиниць генеральної сукупності N і вибіркової сукупності n називають їх обсягами. Значення ознаки X , які попали у вибірку (вибірку), називають *варіантами* і позначають x_i , $i = 1, n$.

Вибірки бувають повторними та неповторними. Вибірка називається *повторною*, якщо перед вибором наступного елемента попередній повертається в генеральну сукупність. Вибірка називається *неповторною*, якщо перед вибором наступного елемента попередній не повертається в генеральну сукупність.

Вибіркову сукупність називають *репрезентативною*, якщо вона досить добре віддзеркалює основні характеристики генеральної сукупності. Щоб за даними вибірки мати можливість робити висновки про генеральну сукупність, вона має бути утворена з навімання взятих елементів, що певною мірою дозволяє знизити можливість помилок репрезентативності. Випадковість елементів у вибірці досягається завдяки принципу рівної можливості всіх елементів генеральної сукупності бути відібраними у вибірку.

Помилка репрезентативності — відхилення вибіркової сукупності за певними характеристиками від генеральної сукупності.

Чим більша величина відхилень, тим значніша помилка репрезентативності й тим нижча якість одержаних даних вибірки. Головне завдання на цьому етапі дослідження — урахувати помилку репрезентативності під час інтерпретації та узагальнення результатів дослідження, проведеного із застосуванням вибіркового методу.

Важливу роль у визначенні якості інформації, одержаної в результаті емпіричного дослідження, крім репрезентативності відіграють такі параметри, як надійність і валідність.

Надійність інформації — адекватність одержаних результатів дослідження випадкових явищ. Забезпечується вона врахуванням так званих випадкових помилок, які є неминучими внаслідок неоднорідності досліджуваних об'єктів. Чим однорідніші об'єкти обстеження і чим більший обсяг вибіркової сукупності, тим незначніша випадкова помилка вибірки і, відповідно, вища якість одержаної інформації. Випадкові помилки виникають також унаслідок низької якості інструментарію, непрофесійної роботи дослідника тощо.

Якість дослідження визначається величиною випадкової помилки (знаходять її за допомогою математичних формул), яку можна врахувати під час поширення висновків, зроблених на підставі вибіркового дослідження, на всю генеральну сукупність.

Валідність (обґрунтованість) інформації — відповідність результатів саме тим явищам і процесам, які передбачалося дослідити.

До зниження валідності можуть призвести не тільки помилки інструментарію, а й систематичні помилки вибірки.

Систематичні помилки виникають унаслідок неправильних вихідних статистичних даних про параметри контрольованих ознак генеральної сукупності, надто малого обсягу вибірки, хибного застосування способу відбору елементів для аналізу тощо.

Установити величину систематичних помилок за допомогою математичних формул неможливо, тому вони значно погіршують результати досліджень і взагалі можуть звести їх нанівець. Крім того, слід ураховувати, що надійність і валідність — самостійні параметри, які не залежать один від одного і характеризують якість дослідження з різних боків. Тому їх обов'язково треба визначати окремо.

Точність результатів вибіркового спостереження, нарешті, залежить від способу вибору елементів, міри коливання ознаки в сукупності та від кількості вибраних елементів.

Вирізняють такі види вибірок:

- власне випадкова вибірка, одержана випадковим вибором елементів без поділу їх на частини або групи;
- механічна вибірка, для якої елементи генеральної сукупності вибираються через деякий інтервал;
- типова вибірка, у котру навмання вибираються елементи з типових груп, на які за певною ознакою поділяється генеральна сукупність;
- серійна вибірка, в яку навмання потрапляють не елементи груп, а власне групи, які потім суцільно досліджуються.

Перед тим як визначити тип вибірки, зупиняються на методі (імовірнісний або цілеспрямований) вибору елементів вибірки.

Вибіркові спостереження за умови правильної їх організації і проведення дають достатньо вірогідні дані, придатні для використання у фінансово-господарському контролі. У контрольно-аудиторському процесі до вибірових спостережень вдаються з метою скорочення обсягу процедур, використовуваних у процесі дослідження об'єктів контролю.

Завдання, які вирішуються за допомогою вибіркового спостереження:

- 1) визначення середнього значення досліджуваної ознаки;
- 2) визначення питомої ваги (частки) досліджуваної ознаки в певній сукупності;
- 3) визначення середньої та граничної похибки вибірки;
- 4) знаходження меж для середньої і частки за повторного і безповторного відбору;
- 5) визначення потрібної чисельності вибірки;
- 6) поширення даних вибіркового спостереження на всю сукупність.

Відповідь на запитання про те, з якою ймовірністю можна стверджувати про збіг між генеральними й вибірковими узагальнювальними показниками, дає теорія вибіркового методу, що ґрунтується на законі великих чисел. За допомогою цього закону вирішують два взаємозв'язаних завдання:

- розраховують за заданої ймовірності межі можливих відхилень вибіркового показника від відповідного показника в генеральній сукупності;
- визначають імовірність перевищення встановленої межі можливими відхиленнями вибіркового показника від генерального.

Масові явища, які вивчає статистика, перебувають під впливом багатьох випадкових чинників. Тому використовуємо основний висновок граничних теорем теорії ймовірностей про те, що сукупна дія багатьох випадкових факторів приводить за деяких умов до результату майже незалежного від випадку. Оскільки вибіркове спостереження пов'язане з випадковими відхиленнями характеристик вибіркової й генеральної сукупностей, то ключове положення граничних теорем дає змогу стверджувати, що результати вибіркового спостереження вірогідні за достатньо великої кількості відібраних елементів. За цих умов вибіркові характеристики надійно відтворюють генеральні характеристики.

Випадкові похибки реєстрації для великої кількості спостережень не впливають суттєво на результат дослідження, оскільки вони взаємно погашаються, а тому від них можна абстрагуватись і надалі розглядати тільки похибки вибірки. Принцип строгої випадковості, який покладено в основу вибірки, забезпечує її об'єктивність, дає змогу встановити межі можливих похибок і дістати майже вірогідні дані для характеристики всієї сукупності явищ.

СТАТИСТИЧНІ РОЗПОДІЛИ ВИБІРКИ.

ЕМПІРИЧНА ФУНКЦІЯ СТАТИСТИЧНОГО РОЗПІДІЛУ. ПОЛІГОН. ГІСТОГРАМА

Варіаційним рядом називається впорядкована статистична сукупність, елементи (варіанти) x_i якої розташовані в порядку зростання.

Якщо елемент x_i зустрічається n_i разів, тоді число n_i називається *частотою* елемента x_i , а відношення $w_i = \frac{n_i}{n}$ — *відносною частотою* елемента x_i .

Статистичним рядом (розподілом) називається послідовність пар (x_i, n_i) , де x_i подано за зростанням значень.

У разі коли обсяг вибірки великий, статистичні дані записують у вигляді інтервального статистичного ряду.

Інтервальним статистичним рядом (розподілом) називається послідовність виділених інтервалів і частот, або відносних частот відповідних їм варіантів.

Для побудови інтервального статистичного ряду множину значень варіант розбивають на інтервали $[a_i; a_{i+1})$, тобто здійснюють їх групування. *Кількість інтервалів k* рекомендується розраховувати за формулою Стерджерса

$$k = 1 + 3,322 \lg n . \quad (1.1)$$

Довжину інтервалу, яку позначають літерою h (або Δ), найчастіше беруть однаковою. Підраховуючи кількість значень варіант, що потрапили в інтервал $[a_i; a_{i+1})$, отримують відповідні інтервалам частоти n_i для $i = \overline{1, k}$.

Нерівні інтервали застосовують тоді, коли кількісні зміни розміру ознаки мають неоднакове значення для нижчих і вищих груп. Так, якщо різниця лише в 2—4 роки для тих, хто одружується в молодому віці (до 30 років), відіграє велику роль, то для людей старшого віку така різниця буде набагато значніша — 10 років і більше.

Якщо значення ознаки змінюється рівномірно, то виділяють рівні інтервали груп. Їхню довжину визначають за формулою

$$h = \frac{x_{\max} - x_{\min}}{k}, \quad (1.2)$$

де $x_{\max} = \max\{x_1, x_2, \dots, x_n\}$; $x_{\min} = \min\{x_1, x_2, \dots, x_n\}$.

Як правило, статистичний ряд записується у вигляді таблиці, перший рядок якої містить варіанти x_i а другий — відповідні їм частоти n_i (табл. 1):

Таблиця . 1

Варіанти x_i	x_1	x_2	...	x_k
Частоти n_i (відносні частоти w_i)	$n_1 (w_1)$	$n_2 (w_2)$	...	$n_k (w_k)$

Інтервальний статистичний ряд у загальному вигляді можна подати таблицею (табл. 2):

Таблиця . 2

Інтервали $[a_i; a_{i+1})$	$[a_1; a_2)$	$[a_2; a_3)$	...	$[a_k; a_{k+1}]$
Частоти n_i (відносні частоти w_i)	$n_1 (w_1)$	$n_2 (w_2)$	...	$n_k (w_k)$

Для статистичних рядів повинні виконуватися умови:

$$\sum_{i=1}^k n_i = n, \quad \sum_{i=1}^k w_i = 1.$$

Для наочності використовують графічне зображення статистичних рядів у вигляді полігону частот (відносних частот) і, тільки в разі інтервального ряду, гістограми частот (відносних частот).

Полігоном частот (відносних частот) називається ламана лінія, що з'єднує прямолінійними відрізками точки з координатами $(x_i; n_i)$ [або $(x_i; w_i)$] для $i = \overline{1, k}$ у разі дискретного статистичного ряду; $(c_i; n_i)$ (або $(c_i; w_i)$) у разі інтервального ряду, де c_i — середина i -го інтервалу, $c_i = \frac{a_i + a_{i+1}}{2}$.

Гістограмою частот (або просто гістограмою), називають ступінчасту фігуру, яка складається з прямокутників, основами яких є частинні інтервали довжиною $h = x_{i+1} - x_i$, а висоти дорівнюють відповідному значенню частоти n_i , поділеному на h , тобто $\frac{n_i}{h}$ (за умови, що всі довжини інтервалів однакові).

Гістограмою відносних частот називається ступінчаста фігура, яка складається з прямокутників, основами яких є окремі інтервали довжиною $h = x_{i+1} - x_i$, а висоти дорівнюють відношенню відносної частоти w_i до h , тобто $\frac{w_i}{h}$.

За статистичним рядом можна знайти емпіричну функцію розподілу випадкової величини X .

Емпіричною функцією розподілу називається функція аргументу x , $x \in \mathbb{R}$, що визначає відносну частоту події $X < x$, що дорівнює відношенню числа n_x — кількості варіант менших за значення x — до обсягу вибірки n :

$$F^*(x) = W(X < x) = \frac{n_x}{n}. \quad (3)$$

Для статистичного ряду графік емпіричної функції розподілу має ступінчастий вигляд, для інтервального статистичного ряду графіком є кумулятивна крива (кумулята), яку одержують, з'єднуючи точки $(a_i; F^*(a_i))$, відрізками прямих, де a_i — кінці інтервалів, $i = \overline{1, k}$.

Властивості емпіричної функції:

- 1) $0 \leq F^*(x) \leq 1$;
- 2) $F^*(x) \Big|_{x \leq x_{\min}} = 0$, де $x_{\min}$ — найменше значення варіанти вибірки;
- 3) $F^*(x) \Big|_{x > x_{\max}} = 1$, де $x_{\max}$ — найбільше значення варіанти вибірки;
- 4) $F^*(x)$ є неспадною функцією аргументу x , а саме $F^*(x_2) \geq F^*(x_1)$ для $x_2 \geq x_1$.

Емпірична функція розподілу виражає для кожного дійсного числа x відносну частоту події $X \leq x$, тобто $F^*(x) = W(X \leq x)$.

Для дискретного статистичного розподілу частот емпірична функція розподілу

$$F^*(x) = \begin{cases} 0, & \text{якщо } x < x_1; \\ \frac{n_1}{n}, & \text{якщо } x_1 \leq x < x_2; \\ \frac{n_1 + n_2}{n}, & \text{якщо } x_2 \leq x < x_3; \\ \dots & \dots \\ \frac{n_1 + n_2 + \dots + n_{k-1}}{n}, & \text{якщо } x_{k-1} \leq x < x_k; \\ 1, & \text{якщо } x \geq x_k; \end{cases} \quad (*)$$

її графік зображений на рис. 1.




Рис. 1. Графік емпіричної функції розподілу у випадку дискретного статистичного розподілу вибірки

На відміну від емпіричної функції розподілу вибірки, інтегральну функцію розподілу генеральної сукупності називають теоретичною інтегральною функцією розподілу. З теореми Бернуллі випливає, що відносна частота події за ймовірністю прямує до ймовірності цієї події. Це означає, що емпірична функція вибірки за ймовірністю прямує до теоретичної функції розподілу генеральної сукупності. Тому емпірична функція розподілу вибірки є оцінкою теоретичної функції генеральної сукупності.

Для побудови кумуляти $F^*(x)$ для інтервального статистичного розподілу вибірки за основу береться припущення, що ознака на кожному частинному інтервалі має рівномірну щільність ймовірностей. Тому кумулята матиме вигляд ламаної лінії, яка зростає на кожному частинному інтервалі і наближається до одиниці.

Інтервальний статистичний розподіл вибірки також характеризується своєю емпіричною функцією розподілу, але, на відміну від дискретного випадку, вона геометрично зображається ламаною лінією, яка з'єднує послідовно точки (z_i, ω_i) , де $\omega_i = w_1 + w_2 + \dots + w_i$, $\omega_0 = 0$ (рис.2).

Для інтервального статистичного розподілу вибірки емпірична функція розподілу $F^*(x)$ має такий аналітичний вигляд:

$$F^*(x) = \begin{cases} 0, & x \leq z_0, \\ F_1^*(x), & z_0 < x \leq z_1, \\ F_2^*(x), & z_1 < x \leq z_2, \\ \dots & \dots \\ F_m^*(x), & z_{m-1} < x \leq z_m, \\ 1, & x > z_m, \end{cases} \quad (**)$$

$$\text{де } F_i^*(x) = \frac{w_i}{z_i - z_{i-1}}(x - z_{i-1}) + \omega_{i-1}, \quad i = \overline{1, m}.$$




Рис. 2. Графік емпіричної функції розподілу у випадку інтервального статистичного розподілу вибірки

Приклад 1. Під час тестування службовців деякої компанії були одержані такі результати (у балах):

39, 41, 40, 42, 41, 40, 42, 44, 40, 43, 38, 42,
41, 43, 39, 37, 43, 41, 38, 42, 40, 41, 42, 40, 41.

Побудувати дискретний статистичний ряд, полігон частот, емпіричну функцію розподілу та її графік

Р о з в ' я з а н н я. Для побудови дискретного статистичного ряду записуємо в порядку зростання різні значення випадкової величини X і відповідні частоти (табл. 3).

Останній стовпчик таблиці використовується для перевірки правильності побудови статистичного ряду (усього в тестуванні взяли участь 25 осіб, тому сума частот має дорівнювати 25).

Таблиця . 3

x_i	37	38	39	40	41	42	43	44	Сума
n_i	1	2	2	4	6	5	4	1	$n = \sum_{i=1}^k n_i = 25$

Полігон частот даного розподілу зображено на рис. 1.




Рис. 1. Полігон частот

Для побудови емпіричної функції розподілу обчислимо суму частот варіант, менших за x (тобто $\sum_{x_i \leq x} n_i$). Дістаємо:

якщо $x < 37$, то $\sum_{x_i \leq 37} n_i = 0$, оскільки таких значень x_i немає, тоді $F^*(x) = 0$;

якщо $37 \leq x < 38$, то $\sum_{x_i \leq 38} n_i = n_1 = 1$, а $F^*(x) = \frac{1}{25}$;

якщо $38 \leq x < 39$, то $\sum_{x_i \leq 39} n_i = n_1 + n_2 = 1 + 2 = 3$, а $F^*(x) = \frac{3}{25}$;

якщо $39 \leq x < 40$, то $\sum_{x_i \leq 40} n_i = n_1 + n_2 + n_3 = 1 + 2 + 2 = 5$, а $F^*(x) = \frac{5}{25}$;

якщо $40 \leq x < 41$ то $\sum_{x_i \leq 41} n_i = n_1 + n_2 + n_3 + n_4 = 1 + 2 + 2 + 4 = 9$, а $F^*(x) = \frac{9}{25}$;

якщо $41 \leq x < 42$, то $\sum_{x_i \leq 42} n_i = n_1 + n_2 + n_3 + n_4 + n_5 = 1 + 2 + 2 + 4 + 6 = 15$, а $F^*(x) = \frac{15}{25}$;

якщо $42 \leq x < 43$, то $\sum_{x_i \leq 43} n_i = n_1 + n_2 + n_3 + n_4 + n_5 + n_6 = 1 + 2 + 2 + 4 + 6 + 5 = 20$, а $F^*(x) = \frac{20}{25}$;

якщо $43 \leq x < 44$, то $\sum_{x_i \leq 44} n_i = n_1 + n_2 + n_3 + n_4 + n_5 + n_6 + n_7 = 1 + 2 + 2 + 4 + 6 + 5 + 4 = 24$, а $F^*(x) = \frac{24}{25}$;

якщо $x \geq 44$, то $\sum_{x_i \leq x} n_i = 25$, адже всі значення x_i менші від будь-якого числа, що перевищує 44; тоді $F^*(x) = 1$.

Згідно з означенням емпірична функція має такий вигляд:

$$F^*(x) = \begin{cases} 0, & x < 37, \\ \frac{1}{25}, & 37 \leq x < 38, \\ \frac{3}{25}, & 38 \leq x < 39, \\ \frac{5}{25}, & 39 \leq x < 40, \\ \frac{9}{25}, & 40 \leq x < 41, \\ \frac{15}{25}, & 41 \leq x < 42, \\ \frac{20}{25}, & 42 \leq x < 43, \\ \frac{24}{25}, & 43 \leq x < 44, \\ 1, & x \geq 44 \end{cases} = \begin{cases} 0, & x < 37, \\ 0,04, & 37 \leq x < 38, \\ 0,12, & 38 \leq x < 39, \\ 0,2, & 39 \leq x < 40, \\ 0,36, & 40 \leq x < 41, \\ 0,6, & 41 \leq x < 42, \\ 0,8, & 42 \leq x < 43, \\ 0,96, & 43 \leq x < 44, \\ 1, & x \geq 44. \end{cases}$$




Рис. 2. Графік емпіричної функції розподілу

Приклад 2. За даними вибіркового дослідження було одержано розподіл родин за доходом на одного їх члена в умовних одиницях (табл. 4). Побудувати інтервальний статистичний ряд, гістограму частот, емпіричну функцію та її графік, полігон частот і полігон відносних частот.

Таблиця 4

28,92	27,54	22,36	29,09	32,19	26,04	17,06	26,83	24,55	33,22
17,53	30,07	36,27	24,24	26,03	31,05	13,94	14,56	21,40	23,04
13,09	38,84	25,57	22,87	6,11	27,79	25,68	16,30	17,93	24,37
28,92	27,54	22,36	29,06	32,19	26,04	17,06	26,83	24,55	33,22
17,53	30,07	36,27	24,24	26,03	31,05	13,94	14,56	21,40	23,04

Р о з в ' я з а н н я. Табл. 4 містить 50 даних, тобто $n = 50$. Для побудови інтервального статистичного ряду знаходимо кількість інтервалів за формулою (1): $k = 1 + 3,322 \lg 50 \approx 6,477$, вибираємо $k = 7$; $x_{\min} = 6,11$, $x_{\max} = 38,84$; довжину кожного інтервалу знаходимо за формулою (2):

$$h = \frac{x_{\max} - x_{\min}}{k} = \frac{38,84 - 6,11}{7} \approx 4,68.$$

Отже, за початок першого інтервалу вибираємо $a_1 = x_{\min} = 6,11$. Тоді

$$a_2 = a_1 + h = 6,11 + 4,68 = 10,79.$$

Аналогічно,

$$a_3 = 15,47; a_4 = 20,15; a_5 = 24,83; a_6 = 29,51; a_7 = 34,19; a_8 = 38,87.$$

Підрахувавши кількість варіант, що потрапили в кожен інтервал, дістаємо інтервальний статистичний ряд (табл. 5).

Таблиця 5

$[a_i; a_{i+1})$	$[6,11; 10,79)$	$[10,79; 15,47)$	$[15,47; 20,15)$	$[20,15; 24,83)$	$[24,83; 29,51)$	$[29,51; 34,19)$	$[34,19; 38,87]$
n_i	1	5	6	12	15	8	3

За даними таблиці 1.5 будують гістограму частот (рис. 3).




Рис. 3. Гістограма частот

Для побудови емпіричної функції розподілу обчислимо за формулою (3) суму відносних частот варіант менших за x [тобто $F^*(x) = \sum_{x_i < x} w_i$]. За x беремо ліву границю кожного інтервалу.

Отримаємо:

якщо $x \leq a_1 = 6,11$, $F^*(x) = \sum_{x_i < 6,11} w_i = 0$, оскільки таких значень x_i немає;

якщо $x = a_2 = 10,79$, то $F^*(x) = \sum_{x_i < 10,79} w_i = w_1 = 0,02$;

якщо $x = a_3 = 15,47$, то $F^*(x) = \sum_{x_i < 15,47} w_i = w_1 + w_2 = 0,02 + 0,1 = 0,12$;

якщо $x = a_4 = 20,15$, то

$$F^*(x) = \sum_{x_i < 20,15} w_i = w_1 + w_2 + w_3 = 0,02 + 0,1 + 0,12 = 0,24$$

якщо $x = a_5 = 24,83$, то $F^*(x) = \sum_{x_i < 24,83} w_i = w_1 + w_2 + w_3 + w_4 =$
 $= 0,02 + 0,1 + 0,12 + 0,24 = 0,48$;

якщо $x = a_6 = 29,51$, то $F^*(x) = \sum_{x_i < 29,51} w_i = w_1 + w_2 + w_3 + w_4 + w_5 =$
 $= 0,02 + 0,1 + 0,12 + 0,24 + 0,3 = 0,78$;

якщо $x = a_7 = 34,19$, то $F^*(x) = \sum_{x_i < 34,19} w_i = w_1 + w_2 + w_3 + w_4 + w_5 + w_6 =$
 $= 0,02 + 0,1 + 0,12 + 0,24 + 0,3 + 0,16 = 0,94$;

якщо $x = a_8 = 38,87$, то

$$F^*(x) = \sum_{x_i < 38,87} w_i = w_1 + w_2 + w_3 + w_4 + w_5 + w_6 + w_7 =$$

 $= 0,02 + 0,1 + 0,12 + 0,24 + 0,3 + 0,16 + 0,06 = 1.$

Останнє значення функції розподілу означає, що всі значення величини X менші за 38,87.
Згідно з означенням емпірична функція має такий вигляд:

x	$x \leq 6,11$	10,79	15,47	20,15	24,83	29,51	34,19	$x \geq 38,87$
$F^*(x)$	0	0,02	0,12	0,24	0,48	0,78	0,94	1

Побудуємо графік емпіричної функції інтервального розподілу, з'єднуючи зазначені точки від-
різками прямих (рис. 6).




Рис. 6 Графік емпіричної функції розподілу

Для побудови полігону частот і полігону відносних частот обчислимо середини кожного інтервалу за формулою $c_i = \frac{a_i + a_{i+1}}{2}$. Дістанемо: $c_1 = \frac{6,11 + 10,79}{2} = 8,45$; $c_2 = 13,13$; $c_3 = 17,81$; $c_4 = 22,49$; $c_5 = 27,17$; $c_6 = 31,85$; $c_7 = 36,51$.

Розрахуємо відносні частоти:

$$w_1 = \frac{n_1}{n} = \frac{1}{50} = 0,02; w_2 = 0,1; w_3 = 0,12; w_4 = 0,24; w_5 = 0,3; w_6 = 0,16; w_7 = 0,06.$$

Результати оформимо у вигляді таблиці (табл. 6), останній стовпчик якої будемо використовувати для перевірки правильності розрахунків.

Таблиця 6

c_i	8,45	13,13	17,81	22,49	27,17	31,85	36,51	Перевірка
n_i	1	5	6	12	15	8	3	$\sum_{i=1}^k n_i = 50$
w_i	0,02	0,1	0,12	0,24	0,3	0,16	0,06	$\sum_{i=1}^k w_i = 1$

За даними табл. 6 будемо полігон частот (рис. 7) і полігон відносних частот (рис. 8).




Рис. 7 . Полігон частот




Рис. 8 . Полігон відносних частот