

# Тема 7. Основи кореляційного аналізу. Побудова регресійних моделей

---

- ☐ Поняття кореляційного зв'язку між досліджуваними величинами
- ☐ Групування даних для кореляційного аналізу.
- ☐ Коефіцієнт кореляції Пірсона.
- ☐ Коефіцієнт кореляції Спірмена.
- ☐ Встановлення виду кореляційної залежності
- ☐ Лінійна регресія
- ☐ Нелінійна регресія

## Поняття кореляційного зв'язку між досліджуваними величинами

В багатьох прикладних задачах необхідно виявити залежність між двома властивостями (ознаками)  $X$  і  $Y$  одного і того ж економічного об'єкта або між певними ознаками різних об'єктів. Якщо вказані ознаки допускають кількісне вимірювання, і, з погляду економічної теорії, виходячи з економічної характеристики об'єкта, ознака  $Y$  залежить від ознаки  $X$ . Тоді  $X$  можна назвати незалежною змінною або **факторною ознакою**, а  $Y$  – залежною змінною або **результативною ознакою**.

Якщо кожному значенню факторної ознаки  $X$  відповідає одне і тільки одне значення результативної ознаки  $Y$ , то говорять, що між цими ознаками існує **функціональний зв'язок**:  $Y = f(X)$ .

Якщо кожному значенню факторної ознаки  $X$  відповідає безліч значень результативної ознаки  $Y$ , то говорять, що між цими ознаками існує **статистичний зв'язок**.

Наприклад, якщо  $X$  приймає  $l$  значень  $X = \{x_1, x_2, \dots, x_l\}$  і кожному її значенню  $x_i$  відповідає множина значень  $Y$ , тобто:

значенню  $x_1$  відповідає множина  $\{y_{11}, y_{12}, \dots, y_{1m_1}\}$ ;

значенню  $x_2$  відповідає множина  $\{y_{21}, y_{22}, \dots, y_{2m_2}\}$ ;

...

значенню  $x_l$  відповідає множина  $\{y_{l1}, y_{l2}, \dots, y_{lm_l}\}$ ,

то між  $X$  та  $Y$  існує статистичний зв'язок.

Вивчення статистичного зв'язку вважається дуже складним і трудомістким процесом, у якому потрібно аналізувати багатовимірні таблиці даних. Тому, зазвичай, вивчається не статистичний, а кореляційний зв'язок між  $X$  та  $Y$ .

Якщо кожному значенню факторної ознаки  $X$  відповідає певне середнє значення результативної ознаки  $Y$ , то говорять, що між цими ознаками існує **кореляційний зв'язок**. Тобто кореляційною є функціональна залежність між значеннями  $X$  і середніми значеннями  $Y$ :  $\bar{Y} = f(X)$ .

Наприклад, якщо  $X$  приймає  $l$  значень  $X = \{x_1, x_2, \dots, x_l\}$  і кожному її значенню  $x_i$  відповідає середнє множини значень  $Y$ , тобто:

$$\text{значенню } x_1 \text{ відповідає } \bar{y}_{x_1} = \frac{y_{11} + y_{12} + \dots + y_{1m_1}}{m_1};$$

$$\text{значенню } x_2 \text{ відповідає } \bar{y}_{x_2} = \frac{y_{21} + y_{22} + \dots + y_{2m_2}}{m_2};$$

$$\dots$$
$$\text{значенню } x_l \text{ відповідає } \bar{y}_{x_l} = \frac{y_{l1} + y_{l2} + \dots + y_{lm_l}}{m_l},$$

то між  $X$  та  $Y$  існує кореляційний зв'язок.

Наприклад, відомо, що з однакових за площею ділянок землі при рівних кількостях внесеного добрива отримують різний урожай. Тому, якщо  $Y$  – урожайність зерна, а  $X$  – кількість внесеного добрива, то функціонального зв'язку між  $X$  та  $Y$  немає. Це пояснюється впливом таких випадкових факторів, як температура повітря, кількість опадів і т. ін. Однак досвід показує, що середній урожай є функцією від кількості добрива, тобто між  $X$  та  $Y$  існує кореляційний зв'язок.

Основними задачами кореляційного аналізу є:

- вивчення сили зв'язку між двома і більше ознаками досліджуваного об'єкта;
- встановлення факторів, що найбільш суттєво впливають на результативну ознаку;
- виявлення невідомих причинно-наслідкових зв'язків між ознаками об'єкта.

## Групування даних для кореляційного аналізу

Вибіркові дані для вивчення кореляційного зв'язку між ознаками  $X$  та  $Y$  мають вигляд пар їх значень:  $(x_1; y_1), (x_2; y_2), \dots, (x_n; y_n)$ ,  $x_i$  – значення величини  $X$ ,  $y_i$  – значення  $Y$ ,  $n$  – кількість пар значень,  $i = \overline{1, n}$ .

Якщо кількість пар значень достатньо велика (принаймні  $n > 20$ ), то для зручності розрахунків дані групуються.

Для групування даних необхідно:

1) Розбити множини значень  $X$  та  $Y$  на інтервали, використовуючи формулу Стерджеса  $k=1+1,4 \ln n$ , кількість інтервалів для  $X$  та  $Y$  може бути різною (позначення:  $k$  – кількість інтервалів для  $X$ ;  $m$  – кількість інтервалів для  $Y$ ).

2) Зобразити дані графічно: побудувати на площині точки з координатами  $(x_i; y_j)$ . В результаті отримується площа, розбита на прямокутники, в кожному з яких може бути множина точок (рис. 1). Вказане графічне зображення вибірових даних називається **полем кореляції**.




Рисунок 1. Поле кореляції

3) Побудувати кореляційну таблицю (табл. 1). В першому рядку, розбитому на дві частини, записуються інтервали  $[a_i; a_{i+1})$  для  $X$  та їх середини  $x_i$ . У першому стовпці, розбитому на дві частини, записуються інтервали  $[b_j; b_{j+1})$  для  $Y$  та їх середини  $y_j$ . В центральній частині таблиці записуються частоти  $n_{ij}$  – кількість точок, що потрапили в прямокутник, обмежений по  $X$  інтервалом  $[a_i; a_{i+1})$  і по  $Y$  інтервалом  $[b_j; b_{j+1})$ . В останньому рядку таблиці записуються частоти  $n_i$  для  $X$  – кількості точок, що потрапили в прямокутники, які відповідають інтервалу  $[a_i; a_{i+1})$ , тобто  $n_i = \sum_{j=1}^m n_{ij}$  – сума частот  $n_{ij}$  в стовпці з номером  $i$ . В останньому стовпці таблиці записуються частоти  $n_j$  для  $Y$  – кількості точок, що потрапили в прямокутники, які відповідають інтервалу  $[b_j; b_{j+1})$ , тобто  $n_j = \sum_{i=1}^k n_{ij}$  – сума частот  $n_{ij}$  в рядку з номером  $j$ .

Кореляційну таблицю можна розглядати як своєрідний подвійний статистичний ряд.

Таблиця 1

| $X$ (інтервали і їх середини)<br>$Y$ (інтервали і їх середини) |       | $[a_1; a_2)$ | $[a_2; a_3)$ | ... | $[a_k; a_{k+1})$ | $n_j = \sum_{i=1}^k n_{ij}$ |
|----------------------------------------------------------------|-------|--------------|--------------|-----|------------------|-----------------------------|
|                                                                |       | $x_1$        | $x_2$        | ... | $x_k$            |                             |
| $[b_1; b_2)$                                                   | $y_1$ | $n_{11}$     | $n_{21}$     | ... | $n_{k1}$         | $n_1$                       |
| $[b_2; b_3)$                                                   | $y_2$ | $n_{12}$     | $n_{22}$     | ... | $n_{k2}$         | $n_2$                       |
| ...                                                            | ...   | ...          | ...          | ... | ...              | ...                         |
| $[b_m; b_{m+1})$                                               | $y_m$ | $n_{1m}$     | $n_{2m}$     | ... | $n_{km}$         | $n_m$                       |
| $n_i = \sum_{j=1}^m n_{ij}$                                    |       | $n_1$        | $n_2$        | ... | $n_k$            |                             |

4) За даними кореляційної таблиці будується ряд, що відображає залежність середнього значення  $Y$  від  $X$  (табл. 2). В першому рядку таблиці записуються середини інтервалів  $x_i$ . В другому – відповідні середні значення  $\bar{y}_{x_i}$ , що знаходяться за формулами:

$$\bar{y}_{x_1} = \frac{y_1 n_{11} + y_2 n_{12} + \dots + y_m n_{1m}}{n_1}; \quad \bar{y}_{x_2} = \frac{y_1 n_{21} + y_2 n_{22} + \dots + y_m n_{2m}}{n_2}; \quad \dots; \\ \bar{y}_{x_k} = \frac{y_1 n_{k1} + y_2 n_{k2} + \dots + y_m n_{km}}{n_k}.$$

Таблиця 2

|                 |                 |                 |     |                 |
|-----------------|-----------------|-----------------|-----|-----------------|
| $x_i$           | $x_1$           | $x_2$           | ... | $x_k$           |
| $\bar{y}_{x_i}$ | $\bar{y}_{x_1}$ | $\bar{y}_{x_2}$ | ... | $\bar{y}_{x_k}$ |
| $n_i$           | $n_1$           | $n_2$           | ... | $n_k$           |

В результаті отримується статистичний ряд, що містить значення  $X$ , відповідні середні значення  $Y$  та частоти. За даними такого ряду проводиться кореляційний аналіз.



## Коефіцієнт кореляції Пірсона

Для оцінки тісноти (або сили) зв'язку між  $X$  та  $Y$  існує коефіцієнт кореляції. У випадку, коли між  $X$  та  $Y$  існує лінійний зв'язок та вибіркові дані розподілені за нормальним законом, використовується **коефіцієнт кореляції Пірсона**, який ще називається параметричним коефіцієнтом кореляції.

Коефіцієнт кореляції Пірсона розраховується за формулою:

$$r = \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\sigma_x \cdot \sigma_y}, \quad (1)$$

де  $\bar{x}$  – вибіркве середнє величини  $X$ ;

$\bar{y}$  – вибіркве середнє величини  $Y$ ;

$\overline{xy}$  – вибіркве середнє величини  $XY$ ;

$\sigma_x$  – вибіркве середнє квадратичне відхилення величини  $X$ ;

$\sigma_y$  – вибіркве середнє квадратичне відхилення величини  $Y$ .

Враховуючи формули для знаходження вибірових середніх і середніх квадратичних відхилень, а саме:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k x_i n_i ; \quad \bar{y} = \frac{1}{n} \sum_{j=1}^m y_j n_j ; \quad \overline{xy} = \frac{1}{n} \sum_{i=1}^k \sum_{j=1}^m x_i y_j n_{ij} ;$$

$$\sigma_x = \sqrt{\frac{1}{n} \sum_{i=1}^k x_i^2 n_i - \left( \frac{1}{n} \sum_{i=1}^k x_i n_i \right)^2} ; \quad \sigma_y = \sqrt{\frac{1}{n} \sum_{j=1}^m y_j^2 n_j - \left( \frac{1}{n} \sum_{j=1}^m y_j n_j \right)^2} ,$$

отримують більш зручну для розрахунків формулу:

$$r = \frac{n \sum_{i=1}^k \sum_{j=1}^m x_i y_j n_{ij} - \left( \sum_{i=1}^k x_i n_i \right) \left( \sum_{j=1}^m y_j n_j \right)}{\sqrt{n \sum_{i=1}^k x_i^2 n_i - \left( \sum_{i=1}^k x_i n_i \right)^2} \sqrt{n \sum_{j=1}^m y_j^2 n_j - \left( \sum_{j=1}^m y_j n_j \right)^2}}. \quad (2)$$

У випадку незгрупованих даних розрахункова формула суттєво спрощується:

$$r = \frac{n \sum_{i=1}^n x_i y_i - \left( \sum_{i=1}^n x_i \right) \left( \sum_{i=1}^n y_i \right)}{\sqrt{n \sum_{i=1}^n x_i^2 - \left( \sum_{i=1}^n x_i \right)^2} \sqrt{n \sum_{i=1}^n y_i^2 - \left( \sum_{i=1}^n y_i \right)^2}}. \quad (3)$$

### Властивості коефіцієнта кореляції Пірсона

1) Коефіцієнт кореляції Пірсона приймає значення на проміжку  $[-1; 1]$ , тобто  $-1 \leq r \leq 1$ .

2) Якщо  $0,3 \leq |r| \leq 0,5$ , то зв'язок вважається слабким; якщо  $0,5 < |r| \leq 0,7$ , то зв'язок вважається середнім;  $0,7 < |r| \leq 1$ , то зв'язок вважається сильним.

3) Якщо  $r > 0$ , то зв'язок називається додатнім, тобто зі збільшенням значень  $X$  значення  $Y$  також збільшуються. Якщо  $r < 0$ , то зв'язок називається від'ємним, тобто зі збільшенням значень  $X$  значення  $Y$  зменшуються.

**Зауваження.** Слід пам'ятати, що коефіцієнт кореляції Пірсона показує силу лінійного зв'язку. Якщо між  $X$  та  $Y$  існує сильний нелінійний зв'язок, коефіцієнт кореляції Пірсона може дорівнювати нулю.

Оскільки сила зв'язку між  $X$  та  $Y$  оцінюється за вибірковими даними, то необхідна перевірка її **статистичної значущості**, тобто оцінка можливості розповсюдити отримані результати на всю генеральну сукупність.

Перевірка статистичної значущості коефіцієнта кореляції Пірсона здійснюється за допомогою так званої  $t$ -статистики, яка розраховується за формулою:

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}}. \quad (4)$$

Розраховане значення  $t$ -статистики порівнюється з критичним значенням  $t_{\text{крит}}$ .  $t_{\text{крит}}$  – табличне значення розподілу Стюдента

Якщо розраховане значення  $t$ -статистики більше критичного  $|t| > t_{\text{крит}}$ , то коефіцієнт кореляції вважається значущим на обраному рівні  $\alpha$ .

**Приклад 1.** За наявними даними про рівень механізації праці  $X$  (%) і продуктивності праці  $Y$  (од. продукції/год.) для 14 однотипних підприємств (табл. 3. ) оцінити тісноту зв'язку між  $X$  і  $Y$ . Визначити можливість розповсюдження результатів розрахунків на всі підприємства такого типу.

Таблиця 3.

|     |    |    |    |    |    |    |    |    |    |    |    |    |    |    |
|-----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|
| $X$ | 32 | 30 | 36 | 40 | 41 | 47 | 56 | 54 | 60 | 55 | 61 | 67 | 69 | 76 |
| $Y$ | 20 | 24 | 28 | 30 | 31 | 33 | 34 | 37 | 38 | 40 | 41 | 43 | 45 | 48 |

**Розв'язок.** Дані табл. 3. є вибіркою значень  $X$  і відповідних значень  $Y$ . Оскільки кількість даних невелика ( $n=14$ ), то їх можна не групувати. Для оцінки тісноти зв'язку між  $X$  і  $Y$  розрахуємо коефіцієнт кореляції Пірсона за формулою ( 3.) для незгрупованих даних. Розрахунки для зручності оформимо у вигляді таблиці (табл. 4).

| $x_i$ | $y_i$ | $x_i^2$ | $y_i^2$ | $x_i y_i$ |
|-------|-------|---------|---------|-----------|
|-------|-------|---------|---------|-----------|

Таблиця 4

| $x_i$ | $y_i$ | $x_i^2$ | $y_i^2$ | $x_i y_i$ |
|-------|-------|---------|---------|-----------|
| 32    | 20    | 1024    | 400     | 640       |
| 30    | 24    | 900     | 576     | 720       |
| 36    | 28    | 1296    | 784     | 1008      |
| 40    | 30    | 1600    | 900     | 1200      |
| 41    | 31    | 1681    | 961     | 1271      |
| 47    | 33    | 2209    | 1089    | 1551      |
| 56    | 34    | 3136    | 1156    | 1904      |
| 54    | 37    | 2916    | 1369    | 1998      |
| 60    | 38    | 3600    | 1444    | 2280      |
| 55    | 40    | 3025    | 1600    | 2200      |
| 61    | 41    | 3721    | 1681    | 2501      |
| 67    | 43    | 4489    | 1849    | 2881      |
| 69    | 45    | 4791    | 2025    | 3105      |
| 76    | 48    | 5779    | 2304    | 3848      |
| Суми  |       |         |         |           |
| 724   | 492   | 40134   | 18138   | 26907     |

Отже,

$$r = \frac{n \sum_{i=1}^n x_i y_i - \left( \sum_{i=1}^n x_i \right) \left( \sum_{j=1}^n y_j \right)}{\sqrt{n \sum_{i=1}^n x_i^2 - \left( \sum_{i=1}^n x_i \right)^2} \sqrt{n \sum_{j=1}^n y_j^2 - \left( \sum_{j=1}^n y_j \right)^2}} =$$

Отже,

$$r = \frac{n \sum_{i=1}^n x_i y_i - \left( \sum_{i=1}^n x_i \right) \left( \sum_{j=1}^n y_j \right)}{\sqrt{n \sum_{i=1}^n x_i^2 - \left( \sum_{i=1}^n x_i \right)^2} \sqrt{n \sum_{j=1}^n y_j^2 - \left( \sum_{j=1}^n y_j \right)^2}} = \frac{14 \cdot 26907 - 724 \cdot 492}{\sqrt{14 \cdot 40134 - 724^2} \sqrt{14 \cdot 18138 - 492^2}}$$
$$= \frac{20490}{\sqrt{37700} \sqrt{11868}} \approx 0,969.$$

За значенням коефіцієнта кореляції можна зробити висновок, що між  $X$  і  $Y$  існує сильний додатній зв'язок.



Перевіримо статистичну значущість знайденого коефіцієнта кореляції Пірсона. Розрахуємо  $t$ -статистику за формулою (4):

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}}.$$

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} = \frac{0,969\sqrt{14-2}}{\sqrt{1-0,969^2}} \approx 13,59. \quad \text{Знайдемо } t_{\text{крит}}, \text{ враховуючи, що}$$

$$l = n - 2 = 14 - 2 = 12. \quad \text{Оберемо рівень значущості } \alpha = 0,01. \quad \text{Тоді } t_{\text{крит}} = 3,055.$$

Оскільки розраховане значення  $t$ -статистики більше критичного  $13,59 > 3,055$ , то коефіцієнт кореляції можна вважати значущим на обраному рівні  $\alpha = 0,01$ .

**Висновок.** Між рівнем механізації праці та її продуктивністю на підприємствах, що досліджувалися, існує сильний додатній зв'язок: чим більше рівень механізації праці, тим вище її продуктивність. Висновок дійсний для всіх підприємств такого типу.

**Приклад 2.** За наявними даними про річний об'єм виробництва  $Y$  (тис. од. продукції) та основні фонди  $X$  (тис. у. од.) для 20 однотипних підприємств (табл. 5) оцінити тісноту зв'язку між  $X$  і  $Y$ . Визначити можливість розповсюдження результатів розрахунків на всі підприємства такого типу.

Таблиця 5

| $Y \backslash X$ | 12,5 | 17,5 | 22,5 | 27,5 |
|------------------|------|------|------|------|
| 20,5             | 1    | –    | –    | –    |
| 21,5             | –    | 2    | –    | –    |
| 22,5             | –    | 1    | 2    | –    |
| 23,5             | –    | –    | 3    | 3    |
| 24,5             | –    | –    | –    | 8    |

**Розв'язок.** Згруповані вибіркові дані (табл. 5) запишемо у вигляді кореляційної таблиці (табл. 6).

Таблиця 6

| $y_j$ | $x_i$ | 12,5 | 17,5 | 22,5 | 27,5 | $n_j$ |
|-------|-------|------|------|------|------|-------|
| 20,5  |       | 1    | 0    | 0    | 0    | 1     |
| 21,5  |       | 0    | 2    | 0    | 0    | 2     |
| 22,5  |       | 0    | 1    | 2    | 0    | 3     |
| 23,5  |       | 0    | 0    | 3    | 3    | 6     |
| 24,5  |       | —    | —    | —    | 8    | 8     |
| $n_i$ |       | 1    | 3    | 5    | 11   |       |

Для розрахунку коефіцієнта кореляції Пірсона скористаємося формулою

$$r = \frac{n \sum_{i=1}^k \sum_{j=1}^m x_i y_j n_{ij} - \left( \sum_{i=1}^k x_i n_i \right) \left( \sum_{j=1}^m y_j n_j \right)}{\sqrt{n \sum_{i=1}^k x_i^2 n_i - \left( \sum_{i=1}^k x_i n_i \right)^2} \sqrt{n \sum_{j=1}^m y_j^2 n_j - \left( \sum_{j=1}^m y_j n_j \right)^2}}. \quad (2)$$

Розрахунки для зручності оформимо у вигляді таблиці (табл. 7).

| $x_i$ | $n_i$ | $y_j$ | $n_j$ | $x_i n_i$ | $y_j n_j$ | $x_i^2$ | $x_i^2 n_i$ | $y_j^2$ | $y_j^2 n_j$ |
|-------|-------|-------|-------|-----------|-----------|---------|-------------|---------|-------------|
|-------|-------|-------|-------|-----------|-----------|---------|-------------|---------|-------------|

Таблиця 7

| $x_i$ | $n_i$ | $y_j$ | $n_j$ | $x_i n_i$ | $y_j n_j$ | $x_i^2$ | $x_i^2 n_i$ | $y_j^2$ | $y_j^2 n_j$ |
|-------|-------|-------|-------|-----------|-----------|---------|-------------|---------|-------------|
| 12,5  | 1     | 20,5  | 1     | 12,5      | 20,5      | 156,25  | 156,25      | 420,25  | 420,25      |
| 17,5  | 3     | 21,5  | 2     | 52,5      | 43        | 306,25  | 918,75      | 462,25  | 924,5       |
| 22,5  | 5     | 22,5  | 3     | 112,5     | 67,5      | 506,25  | 2531,3      | 506,25  | 1518,8      |
| 27,5  | 11    | 23,5  | 6     | 302,5     | 141       | 756,25  | 8318,8      | 552,25  | 3313,5      |
|       |       | 24,5  | 8     |           | 196       |         |             | 600,25  | 4802        |
| Суми  |       |       |       |           |           |         |             |         |             |
|       |       |       |       | 480       | 468       |         | 11925       |         | 10979       |

Окремо розрахуємо  $\sum_{i=1}^k \sum_{j=1}^m x_i y_j n_{ij} :$

$$\sum_{i=1}^4 \sum_{j=1}^5 x_i y_j n_{ij} = 20,5 \cdot 12,5 + 21,5 \cdot 17,5 \cdot 2 + 22,5 \cdot 17,5 + 22,5 \cdot 22,5 + 23,5 \cdot 22,5 \cdot 3 + \\ + 23,5 \cdot 27,5 \cdot 3 + 24,5 \cdot 27,5 \cdot 8 = 11330.$$

Підставимо знайдені суми у формулу (.2):

$$r = \frac{n \sum_{i=1}^k \sum_{j=1}^m x_i y_j n_{ij} - \left( \sum_{i=1}^k x_i n_i \right) \left( \sum_{j=1}^m y_j n_j \right)}{\sqrt{n \sum_{i=1}^k x_i^2 n_i - \left( \sum_{i=1}^k x_i n_i \right)^2} \sqrt{n \sum_{j=1}^m y_j^2 n_j - \left( \sum_{j=1}^m y_j n_j \right)^2}} = \frac{20 \cdot 11330 - 480 \cdot 468}{\sqrt{20 \cdot 11925 - 480^2} \sqrt{20 \cdot 10979 - 468^2}} = \\ = \frac{1960}{90 \cdot 23,58} \approx 0,924.$$

За значенням коефіцієнта кореляції можна зробити висновок, що між  $X$  і  $Y$  існує сильний додатній зв'язок.

За значенням коефіцієнта кореляції можна зробити висновок, що між  $X$  і  $Y$  існує сильний додатній зв'язок.

Перевіримо статистичну значущість знайденого коефіцієнта кореляції Пірсона. Розрахуємо  $t$ -статистику за формулою (4):

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} = \frac{0,924\sqrt{20-2}}{\sqrt{1-0,924^2}} = \frac{3,92}{\sqrt{0,146}} \approx 10,26. \text{ Знайдемо } t_{\text{крит}}, \text{ враховуючи, що}$$

$l = n - 2 = 20 - 2 = 18$ . Оберемо рівень значущості  $\alpha = 0,01$ . Тоді  $t_{\text{крит}} = 2,88$ .

Оскільки розраховане значення  $t$ -статистики більше критичного  $10,26 > 2,88$ , то коефіцієнт кореляції можна вважати значущим на обраному рівні  $\alpha = 0,01$ .

**Висновок.** Між річним об'ємом виробництва та основними фондами на підприємствах, що досліджувалися, існує сильний додатній зв'язок. Висновок дійсний для всіх підприємств такого типу.

# Коефіцієнт кореляції Спірмена

Для оцінки сили зв'язку між  $X$  та  $Y$  у випадку, коли між  $X$  та  $Y$  існує нелінійний зв'язок або вибіркові дані не розподілені за нормальним законом, варто використовувати коефіцієнт кореляції Спірмена.

Коефіцієнт кореляції Спірмена розраховується за формулою:

$$r_s(X, Y) = 1 - \frac{6 \sum_{i=1}^n d_i^2 + T_X + T_Y}{n(n^2 - 1)}, \quad (5)$$

де  $n$  – кількість пар вибірових даних;

$d_i$  – різниці між рангами  $i$ -го значення  $X$  та відповідного значення  $Y$ ;

$T_X, T_Y$  – поправки, пов'язані з однаковими рангами; розраховуються за формулами:

$$T_X = \frac{\sum_{i=1}^{L_X} (T_{Xi}^3 - T_{Xi})}{12}; \quad T_Y = \frac{\sum_{i=1}^{L_Y} (T_{Yi}^3 - T_{Yi})}{12}, \quad (6)$$

де  $L_X, L_Y$  – кількість зв'язок (груп однакових рангів);

$T_{Xi}, T_{Yi}$  – розміри  $i$ -тих зв'язок (кількість елементів в них).



**Зауваження 1.** Ранги присвоюються вибіровим даним звичайним способом

Даним об'єднаної вибірки присвоюються ранги (порядкові номери) за правилом: найменшому значенню присвоюється ранг 1, наступному найменшому – ранг 2 і т. д. При цьому, якщо деякі елементи вибірки співпадають, то їм присвоюються середні ранги. Для цього додаються ранги, які мали б ці елементи, якщо були б різні; розраховується їх середнє арифметичне; кожному із однакових елементів присвоюється ранг, що дорівнює розрахованому середньому арифметичному.

**Зауваження 2.** Статистична значущість коефіцієнта кореляції Спірмена перевіряється так, як і коефіцієнта кореляції Пірсона.

**Приклад 3.** Вивчається залежність між продуктивністю праці робітників  $X$  (тис. грн.) та їх емоційним відношенням до своєї професійної діяльності  $Y$  (бали). Відповідні дані подано у табл. 8. Оцінити силу зв'язку між досліджуваними факторами за коефіцієнтом кореляції Спірмена. Перевірити його статистичну значущість.

Таблиця 8

|     |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |
|-----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|
| $X$ | 52 | 37 | 32 | 26 | 53 | 31 | 36 | 32 | 54 | 64 | 47 | 35 | 34 | 28 | 36 |
| $Y$ | 16 | 12 | 5  | 4  | 17 | 6  | 15 | 7  | 13 | 20 | 10 | 10 | 10 | 5  | 19 |

**Розв'язок.** Дані табл. 8 є вибірковими парами значень  $(x_i; y_i)$ ,  $i = \overline{1, n}$ ;  $n$  – кількість пар,  $n = 15$ . Знайдемо коефіцієнт кореляції Спірмена, необхідні розрахунки оформимо у вигляді таблиці (табл. 9), використовуючи позначення:  $d_{x_i}$  – ранг  $x_i$ ,  $d_{y_i}$  – ранг  $y_i$ .

Таблиця 9

|           |    |    |     |    |    |    |      |      |    |    |    |    |    |      |       |
|-----------|----|----|-----|----|----|----|------|------|----|----|----|----|----|------|-------|
| $x_i$     | 52 | 37 | 32  | 26 | 53 | 31 | 36   | 32   | 54 | 64 | 47 | 35 | 34 | 28   | 36    |
| $y_i$     | 16 | 12 | 5   | 4  | 17 | 6  | 15   | 7    | 13 | 20 | 10 | 10 | 10 | 5    | 19    |
| $d_{x_i}$ | 12 | 10 | 4,5 | 1  | 13 | 3  | 8,5  | 4,5  | 14 | 15 | 11 | 7  | 6  | 2    | 8,5   |
| $d_{y_i}$ | 12 | 9  | 2,5 | 1  | 13 | 4  | 11   | 5    | 10 | 15 | 7  | 7  | 7  | 2,5  | 14    |
| $d_i$     | 0  | -1 | -2  | 0  | 0  | 1  | 2,5  | 0,5  | -4 | 0  | -4 | 0  | 1  | 0,5  | 5,5   |
| $d_i^2$   | 0  | 1  | 4   | 0  | 0  | 1  | 6,25 | 0,25 | 16 | 0  | 16 | 0  | 1  | 0,25 | 30,25 |

Знаходимо суму квадратів різниць рангів:  $\sum_{i=1}^{15} d_i^2 = 1 + 4 + 1 + 6,25 + 0,25 +$   
 $+ 16 + 16 + 1 + 0,25 + 30,25 = 76$ .

Знаходимо поправки, що пов'язані з однаковими рангами. В стрічці рангів  $d_{x_i}$  є дві групи однакових рангів, в першій з них 2 елемента, в другій теж два. Отже,  $L_X = 2$ ,  $T_{X_1} = 2$ ,  $T_{X_2} = 2$ .

В стрічці рангів  $d_{y_i}$  є дві групи однакових рангів, в першій з них 2 елемента, в другій – три елемента. Отже,  $L_Y = 2$ ,  $T_{Y_1} = 2$ ,  $T_{Y_2} = 3$ .

Підставимо отримані дані в формули ( 6) і знайдемо поправки:

$T_X, T_Y$  – поправки, пов’язані з однаковими рангами; розраховуються за формулами:

$$T_X = \frac{\sum_{i=1}^{L_X} (T_{Xi}^3 - T_{Xi})}{12}; \quad T_Y = \frac{\sum_{i=1}^{L_Y} (T_{Yi}^3 - T_{Yi})}{12}, \quad ( 6)$$

де  $L_X, L_Y$  – кількість зв’язок (груп однакових рангів);

$T_{Xi}, T_{Yi}$  – розміри  $i$ -тих зв’язок (кількість елементів в них).

Підставимо отримані дані в формули ( 6) і знайдемо поправки:

$$T_X = \frac{\sum_{i=1}^{L_X} (T_{Xi}^3 - T_{Xi})}{12} = \frac{(2^3 - 2) + (2^3 - 2)}{12} = 1;$$

$$T_Y = \frac{\sum_{i=1}^{L_Y} (T_{Yi}^3 - T_{Yi})}{12} = \frac{(2^3 - 2) + (3^3 - 3)}{12} = 2,5.$$

Обчислимо коефіцієнт кореляції Спірмена за формулою ( 6):

$$r_s(X, Y) = 1 - \frac{6 \sum_{i=1}^n d_i^2 + T_X + T_Y}{n(n^2 - 1)} = 1 - \frac{6 \cdot 76 + 1 + 2,5}{15(15^2 - 1)} \approx 1 - 0,14 = 0,86.$$

Згідно значення коефіцієнта кореляції можна зробити висновок, що між  $X$  та  $Y$  існує сильний додатній зв'язок.

Перевіримо статистичну значущість знайденого коефіцієнта кореляції.

Розрахуємо  $t$ -статистику за формулою ( 4):  $t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} =$

Перевіримо статистичну значущість знайденого коефіцієнта кореляції.

Розрахуємо  $t$ -статистику за формулою ( 4):  $t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} = \frac{0,86\sqrt{15-2}}{\sqrt{1-0,86^2}} \approx 6,17$ .

Знайдемо  $t_{\text{крит}}$ , враховуючи, що  $l = n - 2 = 15 - 2 = 13$ . Оберемо рівень значущості  $\alpha = 0,01$ . Тоді  $t_{\text{крит}} = t(0,01/2; 13) = 3,012$ .

Оскільки розраховане значення  $t$ -статистики більше критичного  $6,17 > 3,012$ , то коефіцієнт кореляції можна вважати значущим на обраному рівні  $\alpha = 0,01$ .

**Висновок.** Між продуктивністю праці та емоційним відношенням працівника до професійної діяльності існує сильний додатний зв'язок. Висновок дійсний для всієї генеральної сукупності, з якої було зроблено вибірку.

# Встановлення виду кореляційної залежності

При вивченні тісноти зв'язку між різними ознаками економічного чи соціального об'єкта головною задачею є встановлення виду кореляційної залежності результативної ознаки ( $Y$ ) від факторної ( $X$ ), тобто виду функціональної залежності  $\bar{Y}=f(X)$ . В першу чергу це пов'язано з необхідністю прогнозування досліджуваних процесів. Математико-статистичний апарат, що дозволяє встановити вид кореляційної залежності називається **регресійним аналізом**, а функція, яка описує цю залежність, називається **рівнянням регресії**.

Регресійний аналіз проводиться за такими етапами:

- 1) Встановлення виду кореляційної залежності результативної ознаки  $Y$  від факторної ознаки  $X$ .
- 2) Побудова регресійної моделі.
- 3) Перевірка статистичної значущості побудованої моделі.

Перший етап регресійного аналізу є найважливішим, оскільки помилки у виборі виду залежності призводять до побудови регресійної моделі, що не відповідає емпіричним даним і не може використовуватися для прогнозування.

Вибіркові дані для вивчення кореляційного зв'язку між ознаками  $X$  та  $Y$ , зазвичай, мають вигляд пар їх значень:  $(x_1; y_1)$ ,  $(x_2; y_2)$ , ...,  $(x_n; y_n)$ ,  $x_i$  – значення величини  $X$ ,  $y_i$  – значення  $Y$ ,  $n$  – кількість пар значень,  $i = \overline{1, n}$ . Якщо їх кількість достатньо велика, то для зручності розрахунків дані групуються

і будується статистичний ряд, що містить значення  $X$ , відповідні середні значення  $Y$  та частоти (табл. 1).

Таблиця 1

|                      |                      |                      |     |                      |
|----------------------|----------------------|----------------------|-----|----------------------|
| $x_i$                | $x_1$                | $x_2$                | ... | $x_k$                |
| $\overline{y_{x_i}}$ | $\overline{y_{x_1}}$ | $\overline{y_{x_2}}$ | ... | $\overline{y_{x_k}}$ |
| $n_i$                | $n_1$                | $n_2$                | ... | $n_k$                |

Згруповані дані (табл. 1) зображуються графічно, що часто дозволяє визначити вид залежності  $Y$  від  $X$ .



Ламана лінія, що сполучає точки з координатами  $(x_i; \overline{y_{x_i}})$ , називається **емпіричною лінією регресії**.

Якщо емпірична лінія регресії значно наближається до прямої лінії, то висувається гіпотеза про наявність лінійного зв'язку між досліджуваними ознаками (рис. 2 ).




Рисунок 2. Гіпотетична лінійна залежність

В іншому випадку висувається гіпотеза про наявність нелінійного зв'язку (рис. 3 ).




Рисунок 3 . Гіпотетична нелінійна залежність

## Лінійна регресія

Якщо висунуто гіпотезу про наявність лінійної залежності результативної ознаки ( $Y$ ) від факторної ( $X$ ), то рівняння регресії має вид:

$$\overline{y_x} = ax + b, \quad (7)$$

де  $a, b$  – параметри моделі.

Побудова лінійної регресійної моделі – це знаходження параметрів рівняння (7). Параметри рівняння регресії можна знайти за **методом найменших квадратів**.

## Ідея методу найменших квадратів

Нехай при вивчення залежності  $Y$  від  $X$  було отримано вибіркові дані:  $x_1, x_2, \dots, x_n$  – значення величини  $X$ ,  $y_1, y_2, \dots, y_n$  – відповідні значення  $Y$ . За вибірковими даними було побудовано рівняння регресії  $y = ax + b$ . Якщо в рівняння підставити замість  $x$  значення  $x_1, x_2, \dots, x_n$ , то будуть отримані теоретичні значення  $Y$ :  $y_{1,теор}, y_{2,теор}, \dots, y_{n,теор}$ , які відрізняються від  $y_1, y_2, \dots, y_n$ . Різниця значень  $y_{i,теор} - y_i$  називається помилкою регресійної моделі і позначається  $e_i$ . Якщо параметри рівняння підбираються так, щоб сума квадратів помилок була мінімальною, то говорять, що вони отримані за методом найменших квадратів.

У випадку лінійної регресії параметри рівняння регресії за методом найменших квадратів знаходяться з системи лінійних алгебраїчних рівнянь:

$$\begin{cases} a \sum_{i=1}^k x_i^2 n_i + b \sum_{i=1}^k x_i n_i = \sum_{i=1}^k x_i n_i \overline{y_{x_i}} \\ a \sum_{i=1}^k x_i n_i + b \sum_{i=1}^k n_i = \sum_{i=1}^k n_i \overline{y_{x_i}} \end{cases} . \quad ( 8 )$$

Якщо вибіркові дані не згруповані, то система ( 7 ) значно спрощується:

$$\begin{cases} a \sum_{i=1}^n x_i^2 + b \sum_{i=1}^n x_i = \sum_{i=1}^n x_i y_i \\ a \sum_{i=1}^n x_i + b n = \sum_{i=1}^n y_i \end{cases} . \quad ( 9 )$$

Перевірка правильності побудови рівняння регресії здійснюється за основним варіаційним рівнянням:

$$Q = Q_p + Q_o, \quad (10)$$

де  $Q = \sum_{i=1}^k (\overline{y_{x_i}} - \overline{y})^2 n_i$  – загальна варіація, тобто сума квадратів відхилень

емпіричних значень  $Y$  від середнього  $\overline{y} = \frac{\sum_{i=1}^k \overline{y_{x_i}} n_i}{n}$ ;

$Q_p = \sum_{i=1}^k (y_{i, теор} - \overline{y})^2 n_i$  – варіація регресії, тобто сума квадратів відхилень

теоретичних значень  $Y$  від середнього, що обумовлена регресією;

$Q_o = \sum_{i=1}^k (y_{i, теор} - \overline{y_{x_i}})^2 n_i$  – варіація залишків, тобто сума квадратів відхилень

теоретичних значень  $Y$  від емпіричних.

У випадку незгрупованих даних загальна варіація, варіації регресії і залишків знаходяться за формулами:  $Q = \sum_{i=1}^n (y_i - \overline{y})^2$ ;  $Q_p = \sum_{i=1}^n (y_{i, теор} - \overline{y})^2$ ;

$Q_o = \sum_{i=1}^n (y_{i, теор} - y_i)^2$ ; а середнє значення за формулою  $\overline{y} = \frac{\sum_{i=1}^n y_i}{n}$ .

Для перевірки статистичної значущості рівняння регресії розраховується  $F$ -статистика за формулою:

$$F = \frac{Q_p (n - l)}{Q_o (l - 1)}, \quad (11)$$

де  $n$  – кількість спостережень,  $l$  – кількість груп у кореляційній таблиці або кількість параметрів моделі у випадку незгрупованих даних. Розраховане значення  $F$ -статистики порівнюється з критичним значенням  $F_{кр}$  розподілу Фішера, яке можна знайти за статистичними таблицями

$$F_{кр} = F(\alpha, k_1, k_2),$$

де  $k_1 = l - 1$ ;  $k_2 = n - l$  – степені свободи,  $\alpha$  – рівень значущості.



Адекватність моделі вибіркоvim даним можна оцінити за коефіцієнтом детермінації  $R^2$ , що показує частину варіації значень результативної ознаки  $Y$ , що пояснюється рівнянням регресії. Коефіцієнт детермінації розраховується за формулою:

$$R^2 = 1 - \frac{Q_o}{Q} = \frac{Q_p}{Q}. \quad (12)$$

Значення коефіцієнта детермінації знаходяться в інтервалі  $[0;1]$ , тобто  $0 \leq R^2 \leq 1$ . Чим ближче  $R^2$  до 1, тим краще отримане рівняння регресії пояснює поведінку результативної ознаки. Наприклад, якщо  $R^2 = 0,98$ , то 98% варіації результативної ознаки  $Y$  пояснюється рівнянням регресії.



**Приклад 1.** Побудувати регресійну модель, що описує залежність сумарних виробничих затрат  $Y$  (тис. грн.) від об'ємів виробництва  $X$  (тис. од.). Відповідні статистичні дані задано у табл. 2.

Таблиця 2

|     |     |     |     |     |     |     |     |     |     |     |
|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|
| $X$ | 41  | 44  | 52  | 57  | 59  | 64  | 68  | 70  | 73  | 75  |
| $Y$ | 670 | 657 | 713 | 736 | 778 | 812 | 833 | 876 | 911 | 932 |

**Розв'язок.** В табл. 2 задано вибіркові дані: значення  $x_i, i = \overline{1, n}$  величини  $X$  та відповідні значення  $y_i, i = \overline{1, n}$ ; кількість пар –  $n = 10$  невелика, тому для проведення регресійного аналізу їх можна не групувати.

Перший етап аналізу: визначимо вид залежності  $Y$  від  $X$ . Побудуємо емпіричну лінію регресії (рис. 4 ).




Рисунок 4 . Емпірична лінія регресії

Оскільки емпірична лінія регресії наближається до прямої лінії, то висуваємо гіпотезу про лінійну залежність  $Y$  від  $X$ , тобто рівняння регресії будемо шукати у вигляді

$$y = ax + b .$$

Другий етап: знайдемо параметри  $a, b$  рівняння регресії, для чого складемо систему ( 9 ) для не згрупованих даних.

$$\begin{cases} a \sum_{i=1}^n x_i^2 + b \sum_{i=1}^n x_i = \sum_{i=1}^n x_i y_i \\ a \sum_{i=1}^n x_i + b n = \sum_{i=1}^n y_i \end{cases} \quad ( 3 )$$

Необхідні розрахунки для зручності оформимо у вигляді таблиці

| Розрахункова таблиця |       |       |       |       |       |       |       |       |       |       | Суми   |
|----------------------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|--------|
| $x_i$                | 41    | 44    | 52    | 57    | 59    | 64    | 68    | 70    | 73    | 75    | 603    |
| $y_i$                | 670   | 657   | 713   | 736   | 778   | 812   | 833   | 876   | 911   | 932   | 7918   |
| $x_i^2$              | 1681  | 1936  | 2704  | 3249  | 3481  | 4096  | 4624  | 4900  | 5329  | 5625  | 37625  |
| $x_i y_i$            | 27470 | 28908 | 37076 | 41952 | 45902 | 51968 | 56644 | 61320 | 66503 | 69900 | 487643 |

Отже, складемо систему для знаходження параметрів рівняння регресії та розв'яжемо її за правилом Крамера:

$$\begin{cases} a \sum_{i=1}^n x_i^2 + b \sum_{i=1}^n x_i = \sum_{i=1}^n x_i y_i \\ a \sum_{i=1}^n x_i + bn = \sum_{i=1}^n y_i \end{cases}$$

$$\begin{cases} 37625a + 603b = 487643 \\ 603a + 10b = 7918 \end{cases}.$$

Знайдемо визначник основної матриці системи, яка складена із коефіцієнтів перед невідомими:  $\Delta = \begin{vmatrix} 37625 & 603 \\ 603 & 10 \end{vmatrix} = 37625 \cdot 10 - 603^2 = 12641$ .

Знайдемо допоміжні визначники, що отримуються із попереднього заміною відповідного стовпця коефіцієнтів на стовпець вільних членів:

$$\Delta a = \begin{vmatrix} 487643 & 603 \\ 7918 & 10 \end{vmatrix} = 487643 \cdot 10 - 603 \cdot 7918 = 101876;$$

$$\Delta b = \begin{vmatrix} 37626 & 487643 \\ 603 & 7918 \end{vmatrix} = 37626 \cdot 7918 - 48743 \cdot 603 = 3866021.$$

Знайдемо невідомі за формулами Крамера:

$$a = \frac{\Delta a}{\Delta} = \frac{101876}{12641} \approx 8,06; \quad b = \frac{\Delta b}{\Delta} = \frac{3866021}{12641} \approx 305,83.$$

Отже, шукане рівняння регресії має вигляд  $y = 8,06x - 305,83$ .

Третій етап: перевіримо правильність побудови моделі за рівнянням ( 10), її статистичну значущість за  $F$ -статистикою ( 11) і адекватність вибірковим даним за коефіцієнтом детермінації (12 ). Для чого знайдемо загальну варіацію, варіації регресії та залишків; необхідні розрахунки оформимо у вигляді таблиці

$$Q = Q_p + Q_o, \quad (10)$$

У випадку незгрупованих даних загальна варіація, варіації регресії і залишків знаходяться за формулами:  $Q = \sum_{i=1}^n (y_i - \bar{y})^2$ ;  $Q_p = \sum_{i=1}^n (y_{i,\text{теор}} - \bar{y})^2$ ;

$$Q_o = \sum_{i=1}^n (y_{i,\text{теор}} - y_i)^2 ; \text{ а середнє значення за формулою } \bar{y} = \frac{\sum_{i=1}^n y_i}{n}.$$

Передусім знайдемо  $\bar{y}$ :

| $x_i$ | $y_i$ | $y_{i,\text{теор}}$ | $(y_i - \bar{y})^2$ | $(y_{i,\text{теор}} - \bar{y})^2$ | $(y_{i,\text{теор}} - y_i)^2$ |
|-------|-------|---------------------|---------------------|-----------------------------------|-------------------------------|
|-------|-------|---------------------|---------------------|-----------------------------------|-------------------------------|

$$\bar{y} = \frac{\sum_{i=1}^n y_i}{n} \approx 791,8.$$

| $x_i$ | $y_i$ | $y_{i,\text{теор}}$ | $(y_i - \bar{y})^2$ | $(y_{i,\text{теор}} - \bar{y})^2$ | $(y_{i,\text{теор}} - y_i)^2$ |
|-------|-------|---------------------|---------------------|-----------------------------------|-------------------------------|
| 41    | 670   | 636,26              | 14835,24            | 24193,32                          | 1138,52                       |
| 44    | 657   | 660,44              | 18171,04            | 17256,64                          | 11,80                         |
| 52    | 713   | 724,91              | 6209,44             | 4474,42                           | 141,82                        |
| 57    | 736   | 765,20              | 3113,64             | 707,31                            | 852,92                        |
| 59    | 778   | 781,32              | 190,44              | 109,77                            | 11,04                         |
| 64    | 812   | 821,62              | 408,04              | 889,17                            | 92,52                         |
| 68    | 833   | 853,86              | 1697,44             | 3850,90                           | 434,96                        |
| 70    | 876   | 869,97              | 7089,64             | 6111,17                           | 36,31                         |
| 73    | 911   | 894,15              | 14208,64            | 10475,83                          | 283,87                        |
| 75    | 932   | 910,27              | 19656,04            | 14035,10                          | 472,20                        |
| Суми  |       |                     | 85579,6             | 82103,63                          | 3475,974                      |

Отже,  $Q = 85579,6$ ;  $Q_p = 82103,63$ ;  $Q_o = 3475,974$ ; тоді основне варіаційне рівняння  $Q = Q_p + Q_o$  для побудованої моделі має вигляд:  $85579,6 = 82103,63 + 3475,974$  і є тотожністю, тому рівняння регресії побудовано правильно.

Для перевірки статистичної значущості рівняння регресії знайдемо  $F$ -статистику, враховуючи, що  $n = 10$ ,  $l = 2$  – оскільки шукали рівняння з двома параметрами:

$$F = \frac{Q_p (n - l)}{Q_o (l - 1)} =$$

Знайдемо  $F_{кр}$ :

Знайдемо коефіцієнт детермінації  $R^2$ :  $R^2 = \frac{Q_p}{Q} =$



$$F = \frac{Q_p (n - l)}{Q_o (l - 1)} = \frac{82103(10 - 2)}{3475,974(2 - 1)} \approx 188,96.$$

$$F_{\text{кр}} = F(0,001; 2 - 1; 10 - 2) \approx 25,41. \quad \text{Розраховане}$$

значення  $F$ -статистики більше критичного, тому регресійна модель є статистично значущою на рівні 0,001.

$$\text{Знайдемо коефіцієнт детермінації } R^2: R^2 = \frac{Q_p}{Q} = \frac{82103,63}{85579,6} \approx 0,96. \text{ Значення}$$

коефіцієнта детермінації свідчить, що 96% варіації результативної ознаки  $Y$  пояснюються рівнянням регресії.

**Висновок:** Сумарні виробничі затрати  $Y$  (тис. грн.) лінійно залежать від об'єму виробництва  $X$  (тис. од.). Залежність описується рівнянням  $y = 8,06x - 305,83$ , яке є статистично значущим на рівні значущості 0,001 та описує 96% вибірових даних.

# Нелінійна регресія

Якщо висунуто гіпотезу про наявність нелінійної залежності результативної ознаки ( $Y$ ) від факторної ( $X$ ), то регресійний аналіз проводиться за тими ж етапами, як і у випадку лінійної залежності. Вид рівнянь регресії і системи для знаходження їх параметрів для нелінійних залежностей, що найчастіше зустрічаються, надано у табл. 5.

Таблиця 5

| Рівняння параболічної регресії:<br>$\overline{y_x} = ax^2 + bx + c$                                                                                                                                                                                                                                                                                                                              |                                                                                                                                                                                                                                                                                         |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Система для знаходження параметрів:                                                                                                                                                                                                                                                                                                                                                              |                                                                                                                                                                                                                                                                                         |
| для згрупованих вибірових даних:                                                                                                                                                                                                                                                                                                                                                                 | для незгрупованих вибірових даних:                                                                                                                                                                                                                                                      |
| $\begin{cases} a \sum_{i=1}^k x_i^4 n_i + b \sum_{i=1}^k x_i^3 n_i + c \sum_{i=1}^k x_i^2 n_i = \sum_{i=1}^k x_i^2 n_i \overline{y_{x_i}} \\ a \sum_{i=1}^k x_i^3 n_i + b \sum_{i=1}^k x_i^2 n_i + c \sum_{i=1}^k x_i n_i = \sum_{i=1}^k x_i n_i \overline{y_{x_i}} \\ a \sum_{i=1}^k x_i^2 n_i + b \sum_{i=1}^k x_i n_i + c \sum_{i=1}^k n_i = \sum_{i=1}^k n_i \overline{y_{x_i}} \end{cases}$ | $\begin{cases} a \sum_{i=1}^n x_i^4 + b \sum_{i=1}^n x_i^3 + c \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i^2 y_i \\ a \sum_{i=1}^n x_i^3 + b \sum_{i=1}^n x_i^2 + c \sum_{i=1}^n x_i = \sum_{i=1}^n x_i y_i \\ a \sum_{i=1}^n x_i^2 + b \sum_{i=1}^n x_i + cn = \sum_{i=1}^n y_i \end{cases}$ |

### Рівняння гіперболічної регресії:

$$\overline{y_x} = \frac{a}{x} + b.$$

### Система для знаходження параметрів:

для згрупованих вибірових даних:

$$\begin{cases} a \sum_{i=1}^k \frac{1}{x_i^2} n_i + b \sum_{i=1}^k \frac{1}{x_i} n_i = \sum_{i=1}^k \frac{1}{x_i} \overline{y_{x_i}} n_i \\ a \sum_{i=1}^k \frac{1}{x_i} n_i + b \sum_{i=1}^k n_i = \sum_{i=1}^k \overline{y_{x_i}} n_i \end{cases}$$

для незгрупованих вибірових даних:

$$\begin{cases} a \sum_{i=1}^n \frac{1}{x_i^2} + b \sum_{i=1}^n \frac{1}{x_i} = \sum_{i=1}^n \frac{1}{x_i} y_i \\ a \sum_{i=1}^n \frac{1}{x_i} + bn = \sum_{i=1}^n y_i \end{cases}$$

**Рівняння показникової регресії:**

$$\overline{y_x} = ba^x.$$

**Система для знаходження параметрів:**

для згрупованих вибірових даних:

$$\begin{cases} \lg a \sum_{i=1}^k x_i^2 n_i + \lg b \sum_{i=1}^k x_i n_i = \sum_{i=1}^k x_i n_i \lg \overline{y_{x_i}} \\ \lg a \sum_{i=1}^k x_i n_i + \lg b \sum_{i=1}^k n_i = \sum_{i=1}^k n_i \lg \overline{y_{x_i}} \end{cases}$$

для незгрупованих вибірових даних:

$$\begin{cases} \lg a \sum_{i=1}^n x_i^2 + \lg b \sum_{i=1}^n x_i = \sum_{i=1}^n x_i \lg y_i \\ \lg a \sum_{i=1}^n x_i + n \lg b = \sum_{i=1}^n \lg y_i \end{cases}$$

Перевірка статистичної значущості нелінійної регресійної моделі також здійснюється за  $F$ -статистикою. При цьому для параболічної регресії кількість параметрів  $l = 3$ , для гіперболічної і показникової –  $l = 2$ .

**Приклад 2.** Дано розподіл однотипних підприємств за об'ємом виробництва  $X$  (тис. од.) і собівартістю одиниці продукції  $Y$  (грн.) (табл. 6). Знайти регресійну модель, що описує залежність собівартості продукції від об'єму виробництва.

Таблиця 6

| $X$ | $Y$ | 10 | 15 | 20 | 25 |
|-----|-----|----|----|----|----|
| 25  | —   | —  | 1  | 2  | —  |
| 50  | —   | 2  | 2  | —  | —  |
| 75  | —   | 5  | 3  | 1  | —  |
| 100 | 1   | 3  | —  | —  | —  |
| 125 | 3   | 1  | 1  | —  | —  |

**Розв'язок.** Для проведення регресійного аналізу за даними табл. 6 побудуємо кореляційну таблицю (табл. 7).

Таблиця 7

| $y_j$ | $x_i$ | 25 | 50 | 75 | 100 | 125 | $n_j$    |
|-------|-------|----|----|----|-----|-----|----------|
| 10    |       | 0  | 0  | 0  | 1   | 3   | 4        |
| 15    |       | 0  | 2  | 5  | 3   | 1   | 11       |
| 20    |       | 1  | 2  | 3  | 0   | 1   | 7        |
| 25    |       | 2  | 0  | 1  | 0   | 0   | 3        |
| $n_i$ |       | 3  | 4  | 9  | 4   | 5   | $n = 25$ |

За даними кореляційної таблиці побудуємо ряд, що відображає залежність середнього значення  $Y$  від  $X$  (табл. 2), для чого знайдемо середні значення  $\bar{y}_{x_i}$  для кожного значення  $x_i$ ,  $i = \overline{1,5}$  і заповнимо табл. 8:

Таблиця 8

|                 |    |    |    |     |     |
|-----------------|----|----|----|-----|-----|
| $x_i$           | 25 | 50 | 75 | 100 | 125 |
| $\bar{y}_{x_i}$ |    |    |    |     |     |
| $n_i$           |    |    |    |     |     |

$$\bar{y}_{x_1} = \frac{y_1 n_{11} + y_2 n_{12} + y_3 n_{13} + y_4 n_{14}}{n_1} =$$

$$\bar{y}_{x_1} = \frac{y_1 n_{11} + y_2 n_{12} + y_3 n_{13} + y_4 n_{14}}{n_1} = \frac{20 \cdot 1 + 25 \cdot 2}{3} \approx 23,33; \quad \bar{y}_{x_2} = \frac{15 \cdot 2 + 20 \cdot 2}{4} = 17,5;$$

$$\bar{y}_{x_3} = \frac{15 \cdot 5 + 20 \cdot 3 + 25 \cdot 1}{9} = 17,78; \quad \bar{y}_{x_4} = \frac{10 \cdot 1 + 15 \cdot 3}{4} = 13,75;$$

$$\bar{y}_{x_5} = \frac{10 \cdot 3 + 15 \cdot 1 + 20 \cdot 1}{5} = 13.$$

Таблица 8

|                 |       |      |       |       |     |
|-----------------|-------|------|-------|-------|-----|
| $x_i$           | 25    | 50   | 75    | 100   | 125 |
| $\bar{y}_{x_i}$ | 23,33 | 17,5 | 17,78 | 13,75 | 13  |
| $n_i$           | 3     | 4    | 9     | 4     | 5   |



Перший етап аналізу: визначимо вид залежності  $Y$  від  $X$ . Побудуємо емпіричну лінію регресії (рис. 5 ).




Рисунок 5 . Емпірична лінія регресії

Оскільки емпірична лінія регресії наближається до гіперболи, то висуваємо гіпотезу про гіперболічну залежність  $Y$  від  $X$ , тобто рівняння

регресії будемо шукати у вигляді  $\overline{y_x} = \frac{a}{x} + b$ .

Другий етап: знайдемо параметри  $a, b$  рівняння регресії, для чого складемо систему для згрупованих даних. Необхідні розрахунки для зручності оформимо у вигляді таблиці (табл. 9), в останньому рядку якої знайдемо відповідні стовпцям суми.

Таблиця 9

| $x_i$ | $\bar{y}_{x_i}$ | $n_i$ | $\frac{1}{x_i}$ | $\frac{1}{x_i} n_i$ | $\frac{1}{x_i^2} n_i$ | $\bar{y}_{x_i} n_i$ | $\frac{1}{x_i} \bar{y}_{x_i} n_i$ |
|-------|-----------------|-------|-----------------|---------------------|-----------------------|---------------------|-----------------------------------|
| 25    | 23,33           | 3     | 0,04            | 0,12                | 0,0048                | 69,99               | 2,7996                            |
| 50    | 17,5            | 4     | 0,02            | 0,08                | 0,0016                | 70                  | 1,4                               |
| 75    | 17,78           | 9     | 0,0133          | 0,12                | 0,0016                | 160,02              | 2,1336                            |
| 100   | 13,75           | 4     | 0,01            | 0,04                | 0,0004                | 55                  | 0,55                              |
| 125   | 13              | 5     | 0,008           | 0,04                | 0,0003                | 65                  | 0,52                              |
| Суми  |                 |       |                 | 0,4                 | 0,0087                | 420,01              | 7,4032                            |

Отже, складемо систему для знаходження параметрів рівняння регресії та розв'яжемо її за правилом Крамера:

$$\begin{cases} a \sum_{i=1}^k \frac{1}{x_i^2} n_i + b \sum_{i=1}^k \frac{1}{x_i} n_i = \sum_{i=1}^k \frac{1}{x_i} \overline{y_{x_i}} n_i \\ a \sum_{i=1}^k \frac{1}{x_i} n_i + b \sum_{i=1}^k n_i = \sum_{i=1}^k \overline{y_{x_i}} n_i \end{cases} \Rightarrow \begin{cases} 0,0087a + 0,4b = 7,4032 \\ 0,4a + 25b = 420,01 \end{cases}.$$

Головний визначник системи:  $\Delta = \begin{vmatrix} 0,00872 & 0,4 \\ 0,4 & 25 \end{vmatrix} = 0,00872 \cdot 25 - 0,4^2 = 0,058.$

Допоміжні визначники:  $\Delta a = \begin{vmatrix} 7,4032 & 0,4 \\ 420 & 25 \end{vmatrix} = 7,4032 \cdot 25 - 0,4 \cdot 420 = 17,076;$

$$\Delta b = \begin{vmatrix} 0,00872 & 7,4032 \\ 0,4 & 420 \end{vmatrix} = 0,00872 \cdot 420 - 7,4032 \cdot 0,4 = 0,701207.$$

Формули Крамера:  $a = \frac{\Delta a}{\Delta} = \frac{17,076}{0,058} \approx 294,41; \quad b = \frac{\Delta b}{\Delta} = \frac{0,7012207}{0,058} \approx 12,09.$

Отже, шукане рівняння регресії має вигляд  $\overline{y_x} = \frac{294,41}{x} + 12,09.$

Третій етап: перевіримо правильність побудови моделі за рівнянням (10), її статистичну значущість за  $F$ -статистикою (11) і адекватність вибірковим даним за коефіцієнтом детермінації (12). Для цього знайдемо загальну варіацію, варіації регресії та залишків; необхідні розрахунки оформимо у вигляді таблиці (табл. 10).

Знайдемо  $\bar{y}$ :  $\bar{y} = \frac{\sum_{i=1}^k \bar{y}_x n_i}{n} \approx 16,8$ .

Таблиця 10

| $x_i$ | $y_i$ | $n_i$ | $y_{i,\text{теор}}$ | $(y_i - \bar{y})^2 n_i$ | $(y_{i,\text{теор}} - \bar{y})^2 n_i$ | $(y_{i,\text{теор}} - y_i)^2 n_i$ |
|-------|-------|-------|---------------------|-------------------------|---------------------------------------|-----------------------------------|
| 25    | 23,33 | 3     | 23,866              | 127,907                 | 149,782                               | 0,863                             |
| 50    | 17,5  | 4     | 17,978              | 1,958                   | 5,547                                 | 0,914                             |
| 75    | 17,78 | 9     | 16,015              | 8,637                   | 5,547                                 | 28,028                            |
| 100   | 13,75 | 4     | 15,034              | 37,220                  | 12,482                                | 6,594                             |
| 125   | 13    | 5     | 14,445              | 72,215                  | 27,737                                | 10,441                            |
| Суми  |       |       |                     | 247,936                 | 201,096                               | 46,840                            |

Отже,  $Q = 247,936$ ;  $Q_p = 201,096$ ;  $Q_o = 46,840$ ; тоді основне варіаційне рівняння  $Q = Q_p + Q_o$  для побудованої моделі має вигляд:  $247,936 = 201,096 + 46,840$  і є тотожністю, тому рівняння регресії побудовано правильно.

Таблиця 10

| $x_i$ | $y_i$ | $n_i$ | $y_{i,\text{теор}}$ | $(y_i - \bar{y})^2 n_i$ | $(y_{i,\text{теор}} - \bar{y})^2 n_i$ | $(y_{i,\text{теор}} - y_i)^2 n_i$ |
|-------|-------|-------|---------------------|-------------------------|---------------------------------------|-----------------------------------|
| 25    | 23,33 | 3     | 23,866              | 127,907                 | 149,782                               | 0,863                             |
| 50    | 17,5  | 4     | 17,978              | 1,958                   | 5,547                                 | 0,914                             |
| 75    | 17,78 | 9     | 16,015              | 8,637                   | 5,547                                 | 28,028                            |
| 100   | 13,75 | 4     | 15,034              | 37,220                  | 12,482                                | 6,594                             |
| 125   | 13    | 5     | 14,445              | 72,215                  | 27,737                                | 10,441                            |
| Суми  |       |       |                     | 247,936                 | 201,096                               | 46,840                            |

Отже,  $Q = 247,936$ ;  $Q_p = 201,096$ ;  $Q_o = 46,840$ ; тоді основне варіаційне рівняння  $Q = Q_p + Q_o$  для побудованої моделі має вигляд:  $247,936 = 201,096 + 46,840$  і є тотожністю, тому рівняння регресії побудовано правильно.

Для перевірки статистичної значущості рівняння регресії знайдемо  $F$ -статистику, враховуючи, що  $n = 25$ ,  $l = 2$  – оскільки шукали рівняння з двома параметрами:

$$F = \frac{Q_p(n-l)}{Q_o(l-1)} = \frac{201,096(25-2)}{46,840(2-1)} \approx 98,75.$$

Знайдемо  $F_{кр}$ :  $F_{кр} = F(0,001, 2-1, 25-2) \approx 14,20$ . Розраховане значення  $F$ -статистики більше критичного, тому регресійна модель є статистично значущою на рівні 0,001.

Знайдемо коефіцієнт детермінації  $R^2$ :  $R^2 = \frac{Q_p}{Q} = \frac{201,096}{247,936} \approx 0,81$ . Значення коефіцієнта детермінації свідчить, що 81% варіації результативної ознаки  $Y$  пояснюється рівнянням регресії.

**Висновок:** Залежність собівартості одиниці продукції  $Y$  (грн.) від об'єму виробництва  $X$  (тис. од.) описується рівнянням  $\bar{y}_x = \frac{294,41}{x} + 12,09$ , яке є статистично значущим на рівні значущості 0,001 та описує 81% вибірових даних.