

Представлення статистичного матеріалу

1. Генеральна і статистична сукупності. Щоб вивчити випадкову величину X , закон розподілу якої невідомий, над нею виконують n незалежних випробувань. Припустимо, що в результаті цих випробувань значення x_1 випадкової величини X спостерігалось n_1 разів, $x_2 - n_2$ разів, ..., $x_k - n_k$ разів. Очевидно, $\sum_{i=1}^k n_i = n$. Спостережувані значення x_i , $i=1, 2, \dots, k$ називаються **варіантами**, числа n_i – **частотами**, відношення $w_i = \frac{n_i}{n}$ – **відносними частотами**.

Множина всіх можливих значень випадкової величини X називається **генеральною сукупністю**, а множина значень x_i ($i=1, 2, \dots, k$), яка одержана в результаті випробувань, – **вибіркою з генеральної сукупності** або **статистичною сукупністю**. Число елементів вибірки називається **обсягом вибірки**.

Послідовність варіант, записаних за зростанням, називається **варіаційним рядом (дискретним варіаційним рядом)**.

Виберемо числа $a \leq \min(x_1, x_2, \dots, x_k)$ і $b \geq \max(x_1, x_2, \dots, x_k)$. Поділимо проміжок $[a, b]$ довільним способом на m інтервалів точками $a = z_0 < z_1 < \dots < z_{m-1} < z_m = b$.

Кількість інтервалів рекомендується розраховувати за формулою Стерджерса

$$k = 1 + 3,322 \lg n.$$

Послідовність інтервалів $(z_0, z_1], (z_1, z_2], \dots, (z_{m-1}, z_m]$ називається **інтервальним варіаційним рядом (неперервним варіаційним рядом)**.

Надалі, через $\tilde{n}_i$ позначатимемо суму частот варіант x_i , які попадають в інтервал $(z_{i-1}, z_i]$; числа $\tilde{n}_i$ називають **накопиченими відносними частотами**.

Якщо $a = \min(x_1, x_2, \dots, x_k)$, то замість півінтервалу $(z_0, z_1]$ запишемо проміжок $[z_0, z_1]$.

Основна задача математичної статистики – вивчення властивостей генеральної сукупності на основі статистичної сукупності. Оскільки ми маємо справу з вивченням властивостей випадкової величини X , то для вирішення цієї задачі використовуємо ймовірнісні методи.

2. Статистичний розподіл вибірки. Статистичну сукупність характеризують **статистичним розподілом вибірки**, який може бути **дискретним** або **інтервальним**. Статистичний розподіл вибірки є аналогом закону розподілу дискретної випадкової величини, який вивчається в теорії ймовірностей.

Дискретним статистичним розподілом вибірки називається відповідність між варіантами та їх частотами або відносними частотами.

Дискретний статистичний розподіл вибірки можна подати у вигляді таблиць:

x_i	x_1	x_2	...	x_k
n_i	n_1	n_2	...	n_k

– дискретний статистичний розподіл частот: $\sum_{i=1}^k n_i = n_1 + n_2 + \dots + n_k = n$;

x_i	x_1	x_2	...	x_k
w_i	w_1	w_2	...	w_k

– дискретний статистичний розподіл відносних частот: $p_i^* = \frac{n_i}{n}$,

$$\sum_{i=1}^k w_i = w_1 + w_2 + \dots + w_k = 1.$$

Інтервальним статистичним розподілом вибірки називається відповідність між інтервалами варіаційного ряду та накопиченими частотами або накопиченими відносними частотами.

Інтервальний статистичний розподіл вибірки також записують у вигляді таблиць:

$(z_{i-1}, z_i]$	$(z_0, z_1]$	$(z_1, z_2]$	...	$(z_{m-1}, z_m]$
$\tilde{n}_i$	$\tilde{n}_1$	$\tilde{n}_2$	...	$\tilde{n}_m$

– інтервальний статистичний розподіл частот, $\sum_{i=1}^m \tilde{n}_i = \tilde{n}_1 + \tilde{n}_2 + \dots + \tilde{n}_m = n$;

$(z_{i-1}, z_i]$	$(z_0, z_1]$	$(z_1, z_2]$	...	$(z_{m-1}, z_m]$
$\tilde{w}_i$	$\tilde{w}_1$	$\tilde{w}_2$	...	$\tilde{w}_m$

– інтервальний розподіл відносних частот, $\sum_{i=1}^m \tilde{w}_i = \tilde{w}_1 + \tilde{w}_2 + \dots + \tilde{w}_m = 1$.

Інтервальний статистичний розподіл вибірки в разі необхідності можна замінити дискретним. Для цього досить частинні інтервали $(z_{i-1}, z_i]$ замінити числами – серединами цих інтервалів (тобто прийняти $x_i = \frac{z_{i-1} + z_i}{2}$), а відповідні їм значення частот (відносних частот) залишити без змін.

3. Полігон та гістограма частот. Статистичний розподіл вибірки можна задати графічно полігоном або гістограмою частот.

Полігоном частот називають ламану, відрізки якої послідовно з'єднують точки $(x_1; n_1), (x_2; n_2), \dots, (x_k; n_k)$ координатної площини.

Щоб побудувати полігон частот, на осі абсцис відкладають варіанти x_i , а на осі ординат – відповідні їм частоти n_i . Далі, точки $(x_i; n_i)$ з'єднують відрізками прямих і отримують полігон частот.

Полігоном відносних частот називають ламану, відрізки якої послідовно з'єднують точки $(x_1; w_1), (x_2; w_2), \dots, (x_k; w_k)$.

Щоб побудувати полігон відносних частот, на осі абсцис відкладають варіанти x_i , а на осі ординат – відповідні їм відносні частоти w_i . Точки $(x_i; w_i)$ послідовно з'єднують відрізками прямих і отримують полігон відносних частот.

Гістограмою частот називається східчаста фігура, яка складена з прямокутників, основами яких є частинні інтервали $(z_{i-1}; z_i]$, $i=1, 2, \dots, m$, а їх висоти $\tilde{h}_i = \frac{\tilde{n}_i}{z_i - z_{i-1}}$.

Щоб побудувати гістограму частот, на осі абсцис відкладають частинні інтервали $(z_{i-1}; z_i]$ і на них, як на основі, будують прямокутники з висотами $\tilde{H}_i$. Площа кожного такого прямокутника дорівнює $\tilde{n}_i$.

Гістограмою відносних частот називається східчаста фігура, яка складена з прямокутників, основами яких є частинні інтервали $(z_{i-1}; z_i]$, а їх висоти $\tilde{h}_i = \frac{\tilde{w}_i}{z_i - z_{i-1}}$.

Щоб побудувати гістограму відносних частот, на осі абсцис відкладаємо частинні інтервали $(z_{i-1}; z_i]$ і на них, як на основі, будуємо прямокутники з висотами $\tilde{h}_i$.

4. Емпірична функція розподілу. Функція розподілу $F(x)$ випадкової величини X визначається рівністю

$$F(x) = P(X < x),$$

і її називають *теоретичною функцією розподілу*.

Позначимо через $\tilde{n}(x)$ накопичену частоту для тих значень випадкової величини X , що менші за будь-яке дійсне число x .

Емпіричною функцією розподілу $F^*(x)$ випадкової величини X називається функція, яка для кожного дійсного числа x дорівнює відношенню $\tilde{n}(x)$ до обсягу вибірки n , тобто

$$F^*(x) = \frac{\tilde{n}(x)}{n}.$$

Емпірична функція розподілу виражає для кожного дійсного числа x відносну частоту події $X < x$, тобто $F^*(x) = W(X < x)$.

Для дискретного статистичного розподілу частот емпірична функція розподілу

$$F^*(x) = \begin{cases} 0, & \text{якщо } x < x_1; \\ \frac{n_1}{n}, & \text{якщо } x_1 \leq x < x_2; \\ \frac{n_1 + n_2}{n}, & \text{якщо } x_2 \leq x < x_3; \\ \dots & \dots \\ \frac{n_1 + n_2 + \dots + n_{k-1}}{n}, & \text{якщо } x_{k-1} \leq x < x_k; \\ 1, & \text{якщо } x \geq x_k; \end{cases} \quad (1)$$

і її графік зображений на рис. 1.




Рис. 1. Графік емпіричної функції розподілу у випадку дискретного статистичного розподілу вибірки

Інтервальний статистичний розподіл вибірки також характеризується своєю емпіричною функцією розподілу, але, на відміну від дискретного випадку, вона геометрично зображається ламаною лінією, яка з'єднує послідовно точки (z_i, ω_i) , де $\omega_i = w_1 + w_2 + \dots + w_i$, $\omega_0 = 0$ (рис.2).

Для інтервального статистичного розподілу вибірки емпірична функція розподілу $F^*(x)$ має такий аналітичний вигляд:

$$F^*(x) = \begin{cases} 0, & x \leq z_0, \\ F_1^*(x), & z_0 < x \leq z_1, \\ F_2^*(x), & z_1 < x \leq z_2, \\ \dots\dots\dots \\ F_m^*(x), & z_{m-1} < x \leq z_m, \\ 1, & x > z_m, \end{cases} \quad (2)$$

$$\text{де } F_i^*(x) = \frac{w_i}{z_i - z_{i-1}}(x - z_{i-1}) + \omega_{i-1}, \quad i = \overline{1, m}.$$




Рис. 2. Графік емпіричної функції розподілу у випадку інтервального статистичного розподілу вибірки

Завдання для аудиторної роботи

Приклад 1. Протягом місяця (30 діб) відділ кібербезпеки банку фіксував максимальну кількість спроб підбору пароля (Brute-force атаку) до внутрішнього сервера за одну годину щодоби. У результаті спостережень було отримано такі дані (кількість атак):

10, 2, 3, 15, 7, 12, 10, 7, 14, 5, 7, 15, 5, 12, 7, 7, 3, 6, 2, 20, 15, 14, 2, 3, 14, 4, 6, 13, 4, 13

Завдання:

1. Побудувати дискретний статистичний розподіл вибірки.
2. Звести його до інтервального, поділивши проміжок на 4 рівні частини.
3. Побудувати полігон частот для дискретного ряду.
4. Побудувати гістограму частот для інтервального ряду.
5. Знайти емпіричну функцію розподілу $F(x)$ для дискретного статистичного розподілу та нарисувати її графік.

Приклад 2. Під час тестування стабільності захищеного VPN-з'єднання було проведено 32 заміри часу затримки передачі пакетів даних (у мілісекундах). Отримано такі результати:

2,2; 7,1; 6,3; 3,9; 5,9; 5,6; 5,6; 4,7; 7,9; 3,2; 6,1; 5,5; 6,4; 6,0; 6,9; 4,7; 6,4; 6,9; 6,7; 7,9; 4,2; 6,7; 6,0; 9,2; 5,5; 6,5; 3,5; 4,9; 7,2; 4,9; 8,9; 5,7

Завдання:

1. Скласти інтервальний варіаційний ряд. (Рекомендовано обрати 5–6 інтервалів для кращої наочності і перевірити яку кількість варто взяти за формулою Стерджерса).
2. Побудувати гістограму частот.
3. Запропонувати гіпотезу про вигляд функції розподілу у генеральній сукупності (наприклад, чи схожий розподіл на нормальний, що свідчить про стабільну роботу мережі, чи він має значну асиметрію через зовнішній вплив).
4. Побудувати емпіричну функцію розподілу $F(x)$ для інтервального ряду та нарисувати її графік.

Приклад 3. Для оцінки стабільності роботи центрального комутатора протягом 25 сесій вимірювався рівень вхідного трафіку (в Мбіт/с). Результати спостережень зафіксовано в наступній таблиці:

Рівень трафіку x_i (Мбіт/с)	20	25	30	35	40	45
Кількість сесій n_i	5	4	5	3	5	5

Для заданої вибірки необхідно виконати наступні дії:

1. Побудувати полігон відносних частот.
2. Знайти емпіричну функцію розподілу $F(x)$.
3. Побудувати графік знайденої функції.
4. Яка ймовірність того, що навантаження не перевищить поріг 35 Мбіт/с?

Приклад 4. Центр моніторингу безпеки протягом 60 годин фіксував кількість спроб несанкціонованого доступу до бази даних за кожну годину. Отримані дані (кількість атак на годину) представлено у формі інтервального статистичного розподілу:

Часовий інтервал $[a_{i-1}, a_i)$ (кількість атак)	0 – 10	10 – 20	20 – 30	30 – 40	40 – 50	50 – 60
Кількість годин n_i	5	12	18	10	4	1

Завдання:

1. Записати інтервальний статистичний розподіл у вигляді дискретного. Для цього замінити інтервали їх серединами.
2. Обчислити відносні частоти для кожного значення.
3. Побудувати гістограму частот. На осі абсцис відкласти інтервали, а на осі ординат — висоти прямокутників $h_i = \frac{n_i}{h}$, де h — крок інтервалу.
4. Знайти емпіричну функцію розподілу $F(x)$ для інтервального розподілу.
5. Побудувати графік емпіричної функції розподілу.

Завдання для самостійної роботи

Завдання 1. Адміністратор безпеки зафіксував кількість одночасних активних сесій на сервері VPN протягом 30 випадкових моментів часу:

4, 7, 6, 4, 5, 5, 7, 9, 5, 6, 6, 6, 4, 7, 8, 5, 9, 7, 7, 5, 8, 6, 4, 5, 7, 6, 7, 9, 6, 6.

Необхідно:

1. Побудувати дискретний варіаційний ряд.
2. Скласти таблицю частот та відносних частот.
3. Побудувати полігон частот та відносних частот.
4. Записати аналітичний вираз для емпіричної функції розподілу $F(x)$ та побудувати її графік.

Завдання 2. Під час аудиту бази даних облікових записів було перевірено довжину (кількість символів) паролів 40 користувачів:

8, 12, 10, 8, 9, 14, 12, 10, 8, 16, 10, 12, 8, 9, 10, 12, 14, 8, 10, 12, 16, 12, 10, 8, 9, 12, 10, 14, 8, 12, 10, 9, 8, 12, 10, 14, 12, 8, 10, 12.

Необхідно:

1. Скласти таблицю розподілу частот.
2. Побудувати полігон відносних частот.
3. Визначити, який відсоток користувачів використовує паролі довжиною менше 10 символів.

Завдання 3. Було проведено заміри об'єму переданих даних (у Мб) за одну секунду на критичному вузлі мережі. Отримано наступні результати:

1.2, 5.4, 12.8, 45.0, 32.1, 15.6, 2.3, 8.9, 18.2, 55.4, 22.1, 14.5, 6.7, 48.9, 30.2, 11.4, 4.5, 25.6, 38.4, 60.1, 1.5, 12.3, 52.4, 28.9, 19.8, 3.4, 16.7, 42.3, 9.1, 35.6.

Необхідно:

1. Побудувати інтервальний варіаційний ряд, розбивши дані на 6 рівних інтервалів.
2. Скласти таблицю частот для інтервального ряду.
3. Побудувати гістограму частот.

Завдання 4. Для детектування можливої DDoS-атаки типу "Slowloris" було виміряно час відповіді сервера (у мс) для 50 послідовних запитів: (Припустимо, значення коливаються від 10 мс до 1500 мс).

22, 18, 1205, 25, 19, 21, 1180, 23, 20, 17, 1310, 24, 22, 1195, 20, 18, 26, 21, 1250, 19, 23, 20, 1210, 22, 17, 25, 21, 1190, 24, 20, 18, 22, 1280, 21, 19, 23, 20, 1350, 24, 22, 18, 21, 1170, 25, 19, 23, 20, 1220, 24, 21

Необхідно:

1. Побудувати інтервальний варіаційний ряд (кількість інтервалів k обрати за правилом Стерджеса: $k = 1 + 3.322 \cdot \lg n$).
2. Побудувати гістограму частот.
3. Зробити висновок: чи спостерігається на гістограмі "важкий хвіст" (одиночні значення з великими затримками), що свідчить про аномалію?

Завдання 5. Зафіксовано час (у хвилинали) активності користувачів у банківському додатку до моменту автоматичного виходу (timeout):

1.5, 2.8, 0.5, 4.2, 1.5, 3.0, 1.5, 5.5, 2.8, 1.5, 0.5, 3.0, 2.8, 1.5, 4.2, 0.5, 1.5, 3.0, 5.5, 1.5

Необхідно:

1. Побудувати варіаційний ряд.
2. Побудувати таблицю частот.
3. Побудувати графік емпіричної функції розподілу $F(x)$.
4. За графіком знайти ймовірність того, що сесія триватиме менше 3 хвилин.

Завдання 6. Під час моніторингу безпеки вебсервера було зафіксовано кількість запитів до критичного файлу конфігурації settings.php з різних IP-адрес протягом години. Отримано наступні дані (кількість запитів):

3, 7, 6, 3, 4, 4, 7, 9, 4, 5, 5, 5, 3, 7, 8, 4, 9, 7, 7, 4, 8, 5, 3, 4, 7, 6, 7, 9, 6, 5

На основі наведених даних необхідно:

1. Побудувати дискретний варіаційний ряд.
2. Скласти таблицю і побудувати полігон частот.
3. Скласти таблицю і побудувати полігон відносних частот.
4. Побудувати гістограму частот, розбивши проміжок на 4 рівних частинних інтервали.
5. Знайти емпіричну функцію розподілу $F(x)$ та побудувати її графік.

Завдання 7. Спеціаліст із цифрової криміналістики досліджує шкідливе програмне забезпечення. Було проведено 40 вимірювань затримки (у мілісекундах) між зверненнями вірусу до командного сервера (C2-server) для визначення періодичності його роботи:

40,25; 40,37; 40,33; 40,28; 40,29; 40,41; 40,35; 40,28; 40,30; 40,31; 40,23; 40,36; 40,31; 40,28; 40,34; 40,32; 40,38; 40,31; 40,30; 40,27; 40,40; 40,32; 40,34; 40,36; 40,30; 40,26; 40,34; 40,29; 40,32; 40,33; 40,30; 40,35; 40,38; 40,24; 40,32; 40,33; 40,26; 40,28; 40,30; 40,32

1. Побудувати дискретний варіаційний ряд.
2. Побудувати інтервальний варіаційний ряд, обравши крок інтервалу $h = 0,04$.
3. Побудувати гістограму частот та полігон частот.
4. Сформулювати висновок: чи свідчить низька варіативність даних про те, що запити генеруються автоматично (ботом), а не людиною?

Завдання 8. Протягом години система моніторингу фіксувала кількість підозрілих запитів від унікальних IP-адрес. Дані вже згруповані за кількістю звернень x_i та кількістю адрес n_i , що зробили таку кількість запитів.

Кількість запитів (x_i)	3	4	5	6	7	8	9
Кількість IP-адрес (n_i)	4	6	4	3	7	2	4

Завдання:

1. Обчислити відносні частоти.
2. Побудувати полігон частот.
3. Побудувати емпіричну функцію розподілу $F(x)$ у вигляді таблиці та аналітичного запису.
4. Накреслити графік $F(x)$.
5. Який відсоток IP-адрес зробив більше 6 запитів за годину?

Завдання 9. Апаратний модуль безпеки провів 40 операцій шифрування. Результати вимірювання часу виконання (латентності) наведені у вигляді інтервального ряду.

Інтервали часу в мкс [a_{i-1}, a_i)	40.23–40.27	40.27–40.31	40.31–40.35	40.35–40.39	40.39–40.43
Кількість операцій, n_i	5	11	15	7	2

Завдання:

1. Побудувати гістограму частот.
2. Обчислити щільність частоти для кожного інтервалу (n_i/h).
3. Побудувати полігон частот, використовуючи середини інтервалів як вузли.
4. Знайти та побудувати емпіричну функцію розподілу для інтервального ряду.

Завдання 10. Аналіз розміру пакетів у байтах, що проходять через фаєрвол.

Розмір пакета (x_i , байт)	40–100	100–500	500–1000	1000–1500
Кількість пакетів (n_i)	120	45	15	220

Завдання:

1. Побудувати гістограму частот.
2. Чому на гістограмі ми бачимо два виражені піки (малі пакети-запити та великі пакети-відповіді)? Чи свідчить велика кількість пакетів у діапазоні 1000-1500 байт про стабільне передавання даних?

Приклад 11. Під час моніторингу мережевої активності корпоративного сервера було зафіксовано часові інтервали (у мілісекундах) між послідовними запитами від невідомого хоста. Результати представлено у формі інтервального статистичного розподілу вибірки:

Часовий інтервал $[a_{i-1}, a_i)$ (мс)	160 – 164	164 – 168	168 – 172	172 – 176	176 – 180	180 – 184	184 – 188	188 – 192
Кількість запитів n_i	4	8	10	16	12	5	3	2

Завдання:

1. Записати інтервальний статистичний розподіл у вигляді дискретного статистичного розподілу (використовуючи середини інтервалів).
2. Побудувати гістограму абсолютних і відносних частот.
3. Побудувати графік емпіричної функції розподілу для інтервального статистичного розподілу вибірки.

Приклад 12. Центр керування мережею зафіксував час (у секундах), необхідний для завантаження та перевірки пакетів оновлень антивірусних баз на 120 віддалених терміналах. Дані представлено у формі інтервального статистичного розподілу:

Час завантаження $[a_{i-1}, a_i)$ (сек.)	0.0 – 2.0	2.0 – 4.0	4.0 – 6.0	6.0 – 8.0	8.0 – 10.0
Кількість терміналів n_i	35	48	20	12	5

Завдання:

1. Побудувати гістограму частот.
2. Побудувати полігон частот (за серединами інтервалів).
3. Визначити, який відсоток терміналів оновлюється довше ніж за 6 секунд.

Приклад 13. Під час тестування продуктивності захищеної бази даних було проведено 45 замірів часу затримки (латентності) при виконанні складних SQL-запитів. Отримано наступні результати (у мілісекундах):

62,15; 62,38; 62,31; 62,28; 62,29; 62,41; 62,35; 62,28; 62,30; 62,31; 62,23; 62,36; 62,31; 62,28;
62,34; 62,32; 62,38; 62,31; 62,30; 62,27; 62,40; 62,32; 62,34; 62,36; 62,30; 62,26; 62,34; 62,29;
62,32; 62,33; 62,30; 62,35; 62,38; 62,24; 62,32; 62,33; 62,26; 62,28; 62,30; 62,32; 62,35; 62,31;
62,29; 62,33; 62,34

Завдання:

1. Даний статистичний матеріал об'єднати у класи, кількість яких визначити за формулою Стерджеса: $k = 1 + 3,322 \cdot \lg n$ (результат округлити до цілого числа).
2. Визначити довжину інтервалу h .
3. Скласти частотну таблицю (інтервальний статистичний розподіл).
4. Побудувати гістограму частот та полігон частот.
5. Знайти емпіричну функцію розподілу та побудувати її графік.