

Критерій Пірсона.

Критерій узгодження Пірсона про вигляд закону розподілу ймовірностей. Однією з найбільш важливих задач математичної статистики є задача про визначення закону розподілу ймовірностей випадкової величини (ознаки генеральної сукупності) за даними вибірки.

Якщо закон розподілу випадкової величини невідомий, то формулюють нульову гіпотезу про вигляд густини розподілу. Наприклад: „випадкова величина має густину нормального розподілу ймовірностей”.

Для перевірки таких гіпотез часто застосовують критерій „*хі-квадрат*” **Пірсона (критерій узгодження)**, який ґрунтується на визначенні відхилення емпіричних характеристик від гіпотетичних характеристик.

Критерій Пірсона (критерій узгодження) має вигляд:

$$K = \sum_{i=1}^m \frac{(n_i - np_i)^2}{np_i} = n \sum_{i=1}^m \frac{(w_i - p_i)^2}{p_i}, \quad (*)$$

де n_i - емпіричні частоти, np_i - теоретичні частоти, w_i - емпіричні відносні частоти, p_i - теоретичні ймовірності, n - обсяг вибірки.

Дана випадкова величина K має закон розподілу χ^2 , який описується густиною

$$R(x, n) = \begin{cases} 0, & x \leq 0; \\ \frac{x^{n-2} e^{-x/2}}{A_n}, & x > 0, \end{cases}$$

і він не залежить від невідомого закону розподілу ймовірностей досліджуваної випадкової величини, а залежить лише від $k = m - s - 1$ ступенів вільності, де m - число інтервалів інтервального розподілу статистичних ймовірностей, s - число параметрів теоретичного розподілу.

Схема перевірки гіпотези про вигляд густини розподілу ймовірностей неперервної випадкової величини за критерієм Пірсона:

- статистичні дані (результати вибірки) записують у вигляді інтервального статистичного розподілу:

$(z_{i-1}, z_i]$	$(z_0, z_1]$	$(z_1, z_2]$	...	$(z_{m-1}, z_m]$
n_i	n_1	n_2	...	n_m

де n - обсяг вибірки, n_i - число варіант вибірки, що попадають в інтервал $(z_{i-1}, z_i]$;

- оскільки перевіряється гіпотеза про те, що генеральна сукупність задовольняє певному (конкретному) закону розподілу з густиною $p(x)$, то для кожного інтервалу $(z_{i-1}, z_i]$ можна визначити теоретичні ймовірності p_i попадання значень випадкової величини в цей інтервал;
- для визначення теоретичних ймовірностей p_i використовуємо формули:

$$p_i = P(z_{i-1} < Z \leq z_i) = F(z_i) - F(z_{i-1}), \quad p_i = \int_{z_{i-1}}^{z_i} f(x) dx;$$

причому $z_0 = -\infty$, $z_m = +\infty$, $\sum_{i=1}^m p_i = 1$.

- одержані результати обчислень зручно записати у вигляді таблиці:

$(z_{i-1}, z_i]$	$(-\infty, z_1]$	$(z_1, z_2]$	...	$(z_{m-1}, +\infty)$
n_i	n_1	n_2	...	n_m
p_i	p_1	p_2	...	p_m

- обчислюють емпіричне значення критерію узгодження Пірсона

$$\chi^2_{\text{емп}} = \sum_{i=1}^m \frac{(n_i - np_i)^2}{np_i}.$$

Випадкова величина Z має відомий розподіл „хі-квадрат” з $k = m - s - 1$ ступенями вільності, де m – число часткових інтервалів в інтервальному варіаційному ряді, s – число параметрів густини гіпотетичного розподілу;

- за даним рівнем значущості α і кількістю $k = m - s - 1$ ступенів вільності знаходимо критичну точку $k_{\text{кр}} = \chi^2_{\text{кр}}(\alpha, k)$ за таблицею критичних значень розподілу χ^2 (див. „Додаток 5”);
- співставляємо значення $\chi^2_{\text{емп}}$ і $k_{\text{кр}}$: якщо $\chi^2_{\text{емп}} \geq k_{\text{кр}}$, то гіпотезу H_0 про вигляд густини розподілу відхиляють; якщо ж $\chi^2_{\text{емп}} < k_{\text{кр}}$, то гіпотезу H_0 приймають.

Схема перевірки гіпотези про вигляд закону розподілу ймовірностей дискретної випадкової величини має незначні відмінності:

- статистичні дані (результати вибірки) записують у вигляді дискретного статистичного розподілу:

x_i	x_1	x_2	...	x_m
n_i	n_1	n_2	...	n_m

- на підставі гіпотетичного закону розподілу знаходимо теоретичні ймовірності p_i того, що випадкова величина приймає значення x_i .

Зауваження. Критерій Пірсона застосовують для великих обсягів вибірок, $n \geq 100$. Також мають виконуватись умови $n_i \geq 5$, $np_i \geq 5$ в окремих групах. Якщо ці умови не виконуються, сусідні групи слід об'єднати.

Гіпотетичний закон розподілу може містити невідомі параметри, тоді за їх значення беруть їх точкові оцінки на основі даної вибірки.

1) Біномний закон розподілу.

Випадкова величина ξ може набувати цілих значень $0, 1, \dots, N$ з імовірностями $p_i = P(\xi = i) = C_N^i p^i (1-p)^{N-i}$, де p - параметр розподілу ($0 < p < 1$), який, якщо він невідомий, можна оцінити на основі даних вибірки $p = \frac{\bar{x}}{N}$.

2) Закон розподілу Пуассона

Випадкова величина ξ може набувати цілих значень $0, 1, \dots, m, \dots$ з імовірностями

$$p_i = P(\xi = i) = e^{-\lambda} \frac{\lambda^i}{i!}, \text{ де } \lambda > 0 - \text{ параметр розподілу, який, якщо він невідомий,}$$

можна оцінити на основі даних вибірки $\lambda = \bar{x}$.

- 3) Рівномірний закон розподілу. Функція розподілу має вигляд

$$F(x) = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & a \leq x < b \\ 1, & x \geq b \end{cases}$$

Тут a, b - параметри розподілу, можуть бути оцінені на основі даних вибірки $a = \bar{x} - \sqrt{3} \sigma$, $b = \bar{x} + \sqrt{3} \sigma$, $\sigma = \sqrt{D}$.

- 4) Показниковий закон розподілу. Функція розподілу

$$F(x) = \begin{cases} 0, & x < 0 \\ 1 - e^{-\lambda x}, & x \geq 0 \end{cases}$$

$\lambda > 0$ - параметр розподілу, його точкова оцінка на основі вибірки $\lambda = \frac{1}{\bar{x}}$.

- 5) Нормальний закон розподілу

$$F(x) = \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{(t-a)^2}{2\sigma^2}} dt,$$

Параметри розподілу оцінюються на основі даних вибірки

$$a = \bar{x}, \sigma = \sqrt{D}.$$

Відзначимо, що поряд з критерієм Пірсона є ще інші критерії перевірки гіпотез про закони розподілу випадкових величин, зокрема, критерій Колмогорова.

Завдання для аудиторної роботи

Завдання 1. Під час моніторингу безпеки корпоративної мережі було зафіксовано $n = 120$ спроб несанкціонованого доступу. Система виявлення вторгнень (IDS) класифікувала ці атаки за трьома типами: $m_1 = 43$ атаки було спрямовано на веб-сервери (І тип); $m_2 = 52$ атаки — на бази даних (ІІ тип); $m_3 = 25$ атак — на термінали користувачів (ІІІ тип). Використовуючи критерій згоди Пірсона, перевірте гіпотезу про те, що ймовірність атаки кожного із трьох типів є однаковою (тобто атаки розподілені рівномірно).

Завдання 2. Відділ кібербезпеки проводить аудит системи виявлення аномального трафіку. Було проведено серію з 100 незалежних експериментів. Кожен експеримент складався з 5 спроб передачі шкідливого пакету через фільтр, де апіорна ймовірність того, що система пропустить пакет (подія А), становить $p = 0.3$. За результатами аудиту було отримано такий розподіл кількості пропущених пакетів (x_i) у кожному експерименті:

Кількість пропущених пакетів x_i	0	1	2	3	4	5
Кількість експериментів $\tilde{n}_i$	2	10	27	32	23	6

Перевірте гіпотезу про те, що випадкова величина (кількість пропущених пакетів) дійсно підпорядковується біномному закону розподілу.

Завдання 3. Департамент безпеки програмного забезпечення провів аудит 100 незалежних модулів (партій коду) одного з криптографічних застосунків. У кожному модулі було проаналізовано 5 критичних функцій. У результаті отримано наступний емпіричний розподіл, де x_i — кількість вразливих функцій в одному модулі, а $\tilde{n}_i$ — кількість таких модулів:

Кількість вразливостей x_i	0	1	2	3	4	5
Кількість модулів $\tilde{n}_i$	9	15	20	35	15	6

Використовуючи статистичні методи, перевірте гіпотезу про те, що розподіл кількості вразливостей у коді підпорядковується біномному закону розподілу.

Завдання 4. Спеціалісти з моніторингу безпеки мережі проаналізували 500 сесій передачі даних. Під час перевірки вивчався відсоток службових заголовків (x_i), які містять нетипові або "сміттєві" біти, що можуть свідчити про спробу стеганографічного приховування інформації. Отримано таку залежність між відсотком таких заголовків та кількістю сесій ($\tilde{n}_i$):

Відсоток аномалій, x_i	0	1	2	3	4	5
Кількість сесій, $\tilde{n}_i$	255	100	80	30	25	10

Перевірити нульову гіпотезу H_0 : відсоток аномальних даних у сесії підпорядковується закону розподілу Пуассона, якщо прийнятий рівень значущості $\alpha = 0.05$.

Завдання 5. При дослідженні параметрів якості обслуговування (QoS) захищеного з'єднання було проведено $n = 100$ замірів часу затримки пакетів (у мілісекундах) понад базовий рівень. Отримані результати згруповано в інтервальний статистичний ряд:

Інтервал затримки, $(a_{i-1}; a_i]$	(2; 4]	(4; 6]	(6; 8]	(8; 10]	(10; 12]
Кількість пакетів, n_i	24	16	17	22	21

Використовуючи критерій Пірсона, при рівні значущості 0.05 перевірити гіпотезу про те, що затримка в каналі розподілена рівномірно.

Завдання 6. Для перевірки стійкості системи захисту від DoS-атак адміністратор проаналізував час затримки (латентність) між запитами, що надходять від одного підозрілого вузла. Було проведено $n = 100$ замірів. Гіпотеза полягає в тому, що атакуючий скрипт імітує випадкові затримки, які рівномірно розподілені на проміжку $[0; 10]$ мс. Отримані результати згруповано в інтервальний ряд:

Інтервал затримки, $(a_{i-1}; a_i]$	(0; 2]	(2; 4]	(4; 6]	(6; 8]	(8; 10]
Кількість пакетів, n_i	24	16	17	22	21

Використовуючи критерій згоди Пірсона, при рівні значущості 0.01 перевірте гіпотезу про те, що час затримки дійсно розподілений рівномірно на проміжку $[0; 10]$.

Завдання 7. Група реагування на інциденти (CERT) проаналізувала часові інтервали між критичними збоями в роботі мережевого екрана. Було зібрано вибірку даних про тривалість безперервної роботи системи (у годинах) до моменту виникнення наступної відмови. Результати подано у вигляді інтервального ряду частот:

Часовий інтервал, $(a_{i-1}; a_i]$	0-4	4-8	8-12	12-16	16-20	20-24
Кількість випадків $\tilde{n}_i$	133	45	15	4	2	1

Використовуючи статистичні критерії згоди, перевірте гіпотезу про те, що час безвідмовної роботи системи підпорядковується експонентному (показниковому) закону розподілу.

Завдання 8. Під час моніторингу безпеки корпоративної мережі було проведено аналіз 250 мережевих пакетів (вибірка) з метою виявлення відхилень у часі затримки (jitter) відносно еталонного значення. Результати спостережень за відсотковим відношенням фактичного часу затримки до номінального для 250 пакетів наведено у таблиці:

Інтервал відхилення, $(a_{i-1}; a_i]$	94-98	98-102	102-106	106-110	110-114
Кількість пакетів, $\tilde{n}_i$	42	64	80	48	16

Для заданого рівня значущості 0,01 перевірити статистичну гіпотезу про те, що випадкова величина (відсоткове відношення затримок) підпорядковується нормальному закону розподілу.

Завдання для самостійної роботи

Завдання 1. Для забезпечення надійності шифрування було проведено аудит генератора псевдовипадкових бітів. Під час генерації послідовності довжиною $n = 100$ бітів, значення «1» (логічна одиниця) з'явилося 63 рази. Використовуючи статистичні методи, перевірте, чи узгоджується отриманий результат із гіпотезою про «неупередженість» генератора, тобто про сталу ймовірність випадання одиниці $p = 0.5$.

Завдання 2. В ході дослідження інциденту кібербезпеки було проаналізовано лог-файли міжмережевого екрана (firewall), який зафіксував $n = 900$ запитів до шести критичних портів сервера. Адміністратор підозрює, що зловмисник використовує скрипт для рівномірного сканування, щоб уникнути виявлення системами захисту. Було отримано наступні дані щодо кількості запитів до кожного порту : порт №6: **140** запитів; порт №5: **160** запитів; порт №4: **170** запитів; порт №3: **150** запитів; порт №2: **125** запитів; порт №1: **155** запитів. Використовуючи статистичний критерій Пірсона, перевірте гіпотезу про те, що ймовірність звернення до кожного з шести портів є однаковою ($p = 1/6$). Чи можна вважати цей процес статистично рівномірним, чи спостерігається аномальне фокусування на певних портах?

Завдання 3. Адміністратор безпеки аналізує роботу системи запобігання витоку даних (DLP). Протягом робочого тижня було проведено $N = 100$ сесій перевірки файлів на наявність конфіденційної інформації. У кожній сесії перевірялося по 5 документів. Априорна ймовірність того, що документ містить порушення політики безпеки, становить $p = 0.4$. За результатами аудиту було отримано такий розподіл кількості виявлених порушень (x_i) у кожній сесії:

Кількість порушень, x_i	0	1	2	3	4	5
Кількість сесій $\tilde{n}_i$	5	22	35	25	10	3

Використовуючи критерій згоди Пірсона, перевірте нульову гіпотезу про те, що кількість порушень підпорядковується біномному закону розподілу $B(5, 0.4)$.

Завдання 4. Під час тестування нового антивірусного сканера було проведено серію з 100 перевірок пакетів програм на наявність загроз. Кожен пакет містив по 5 окремих виконуваних файлів. Згідно з технічною документацією, априорна ймовірність того, що файл буде розпізнаний як потенційно небезпечний (через особливості коду), становить $p = 0.2$. За результатами тестування було отримано такий емпіричний розподіл кількості виявлених «загроз» (x_i) у кожному пакеті:

Кількість виявлених загроз, x_i	0	1	2	3	4	5
Кількість пакетів $\tilde{n}_i$	35	38	20	5	2	0

Використовуючи критерій згоди Пірсона, перевірте гіпотезу про те, що кількість виявлених загроз підпорядковується біномному закону розподілу.

Завдання 5. Відділ моніторингу безпеки хмарних сервісів проаналізував 100 віртуальних контейнерів на предмет некоректних налаштувань прав доступу. У кожному контейнері було перевірено 5 критичних параметрів конфігурації. За результатами аудиту було отримано такий емпіричний розподіл кількості виявлених помилок (x_i) у кожному контейнері:

Кількість помилок, x_i	0	1	2	3	4	5
Кількість контейнерів $\tilde{n}_i$	30	35	20	10	4	1

Використовуючи статистичні методи, перевірте гіпотезу H_0 про те, що розподіл кількості помилок у конфігурації підпорядковується біномному закону розподілу.

Завдання 6. Під час моніторингу захищеного каналу зв'язку через рівні проміжки часу реєструвалася кількість спроб несанкціонованого звернення до заблокованого порту (події безпеки). Результати спостережень наведено в наступній таблиці:

Число інцидентів, x_i	0	1	2	3	4
Частота спостережень $\tilde{n}_i$	116	56	22	4	2

Користуючись критерієм χ^2 , перевірити гіпотезу про погодженість цих експериментальних даних із розподілом Пуассона. Рівень значущості прийняти $\alpha = 0.05$.

Завдання 7. Під час тестування пропускної здатності захищеного VPN-шлюзу було проведено $n = 120$ вимірювань часу обробки запиту (латентності) у мілісекундах. Отримані результати були згруповані в інтервальный статистичний ряд:

Інтервал затримки, $(a_{i-1}; a_i]$	(5; 10]	(10; 15]	(15; 20]	(20; 25]	(25; 30]
Кількість пакетів, n_i	18	31	22	29	20

Використовуючи критерій Пірсона, при рівні значущості 0.01 перевірте гіпотезу про те, що час обробки запитів у каналі розподілений рівномірно.

Завдання 8. Під час розслідування кіберінциденту було проаналізовано 1000 пакетів даних. Для перевірки гіпотези про використання специфічного алгоритму затримки (jitter), аналітики зафіксували дробову частину мітки часу приходу кожного пакета (у відносних одиницях від 0 до 12). Результати розподілу пакетів за інтервалами наведено у таблиці:

Інтервали часу, $(a_{i-1}; a_i]$	[0, 1]	(1, 2]	(2, 3]	(3, 4]	(4, 5]	(5, 6]	(6, 7]	(7, 8]	(8, 9]	(9, 10]	(10, 11]	(11, 12]
Кількість пакетів	77	81	95	86	97	90	74	70	77	82	84	87

Перевірити нульову гіпотезу H_0 : значення часових міток пакетів рівномірно розподілені на інтервалі [0, 12].

Завдання 9. Під час проведення сертифікаційних випробувань партії з 100 апаратних модулів шифрування було проведено заміри відхилення тактової частоти генераторів від номінального значення. Результати вимірювань зафіксовано у 5 класах точності:

Відхилення, $(a_{i-1}; a_i]$	0,5-1,5	1,5-2,5	2,5-3,5	3,5-4,5	4,5-5,5
Кількість модулів $\tilde{n}_i$	31	28	31	30	30

Перевірити нульову гіпотезу H_0 : відхилення параметрів роботи модулів від номіналу підпорядковується експонентному (показниковому) закону розподілу.

Завдання 10. Служба кібербезпеки банку аналізує інтервали часу (у хвилинах) між послідовними спробами несанкціонованого доступу до бази даних. Було зафіксовано $n = 100$

таких інтервалів. Гіпотеза H_0 полягає в тому, що час між атаками розподілений за показниковим законом. Результати спостережень представлені у вигляді інтервального ряду:

Інтервал часу (хв), $(a_{i-1}; a_i]$	(0;5]	(5;10]	(10;15]	(15;20]	(20;25]
Кількість інтервалів $\tilde{n}_i$	42	25	15	10	8

Використовуючи критерій згоди Пірсона, перевірте гіпотезу про показниковий розподіл при рівні значущості 0.01.

Завдання 11. Аналітик безпеки досліджує тривалість сесій користувачів корпоративного порталу для виявлення аномальної поведінки. Було зібрано дані про 200 сесій. Гіпотеза H_0 полягає в тому, що тривалість сесії підпорядковується нормальному закону розподілу. Дані згруповано в інтервальный ряд:

Інтервал тривалості, $(a_{i-1}; a_i]$	(10;20]	(20;30]	(30;40]	(40;50]	(50;60]
Кількість сесій $\tilde{n}_i$	18	54	72	40	16

Використовуючи критерій згоди Пірсона, перевірте гіпотезу про нормальний розподіл тривалості сесій при рівні значущості 0.05.

Завдання 12. Система моніторингу безпеки зафіксувала час виконання криптографічних запитів (у мілісекундах) для 100 сесій зв'язку. Отримано інтервальный статистичний розподіл випадкової величини — тривалості обробки запиту:

Часовий інтервал, $(a_{i-1}; a_i]$	80-90	90-100	100-110	110-120	120-130
Кількість запитів, $\tilde{n}_i$	2	14	60	20	4

Використовуючи критерій згоди Пірсона, перевірте припущення, що генеральна сукупність часу обробки запитів має нормальний закон розподілу з параметрами $N(106, 7.6)$, де $\mu=106$ — математичне сподівання, $\sigma = 7,6$ — середнє квадратичне відхилення.

Завдання 13. Для ідентифікації прихованого каналу зв'язку (C2-channel) шкідливого ПЗ, аналітик безпеки дослідив 100 підозрілих пакетів у мережі. Було зафіксовано розподіл розміру корисного навантаження (payload) пакетів у байтах:

Розмір пакета, $(a_{i-1}; a_i]$	75-79	79-83	83-87	87-91	91-95
Кількість пакетів, $\tilde{n}_i$	15	35	20	18	12

Перевірити статистичну гіпотезу про те, що розмір пакетів підпорядковується нормальному закону розподілу.

Завдання 14. Для моніторингу мережевої активності аналітик безпеки дослідив 200 підозрілих пакетів, що можуть належати до прихованого каналу зв'язку (C2-channel). Відомо з попередніх досліджень (або специфікації протоколу), що розмір пакетів такого типу має підпорядковуватися нормальному закону розподілу з параметрами: математичне сподівання

85 байт та середньоквадратичне відхилення 10 байт. Було зафіксовано розподіл розміру корисного навантаження (payload) пакетів у байтах:

Розмір пакета, $(a_{i-1}; a_i]$	60-70	70-80	80-90	90-100	100-110
Кількість пакетів, $\tilde{n}_i$	20	50	75	40	15

Використовуючи критерій згоди Пірсона, перевірити статистичну гіпотезу про те, що отримані дані справді відповідають нормальному розподілу $N(85, 10)$ при рівні значущості 0,05.

Завдання 15. Під час аналізу трафіку для виявлення аномалій, безпековий аналітик зібрав дані про часові інтервали (в мілісекундах) між пакетами у підозрілій сесії. Згідно з документацією прикладного ПЗ, середній час затримки між пакетами становить $a = 35$ мс. Результати групування 100 спостережень наведено в таблиці:

Інтервал часу, $(a_{i-1}; a_i]$	10-20	20-30	30-40	40-50	50-60
Кількість пакетів, $\tilde{n}_i$	12	28	35	18	7

Перевірити гіпотезу H_0 про те, що інтервали затримки розподілені за нормальним законом з відомим середнім $a=35$ та оціненим за вибіркою значенням σ . Рівень значущості прийняти 0,01.