

Двовибірковий критерій погодженості Смірнова

Нехай $x_1, \dots, x_n$ - вибірка з випадкової змінної X , а незалежна від неї вибірка $y_1, \dots, y_m$ - з випадкової змінної Y . Потрібно перевірити таку нульову гіпотезу: обидві генеральні сукупності керовані однією і тією ж неперервною функцією розподілу, тобто ξ і η - стохастично еквівалентні.

На основі вибірок знаходимо емпіричні функції розподілу цих статистичних змінних:

$$F_n(x) = \begin{cases} 0, & x < x_{(1)} \\ \frac{n_i}{n}, & x_{(i)} \leq x < x_{(i+1)}, \quad i = 1, \dots, n-1 \\ 1, & x_{(n)} \leq x, \end{cases}$$

де n_i - кількість елементів $x_{(i)}$ - кількість елементів варіаційного ряду першої вибірки, які не більші за x та:

$$G_m(x) = \begin{cases} 0, & x < y_{(1)} \\ \frac{m_i}{m}, & y_{(i)} \leq x < y_{(i+1)}, \quad i = 1, \dots, m-1 \\ 1, & y_{(m)} \leq x, \end{cases}$$

де m_i - кількість елементів $y_{(i)}$ - кількість елементів варіаційного ряду другої вибірки, які не більші за x .

Розглянемо статистику: $D_{nm} = \sup_{-\infty < x < \infty} |F_n(x) - G_m(x)|$.

У 1999р. Смірнов довів, що статистика $S_{nm} = \sqrt{\frac{mn}{m+n}} D_{nm}$.

при $n \rightarrow \infty, m \rightarrow \infty$ має розподіл Колмогорова.

Алгоритм критерію Смірнова:

- 1) Вибираємо рівень значущості α .
- 2) Будуємо спільний варіаційний ряд даних двох вибірок
- 3) Знаходимо $(S_{nm})_{емп}$.
- 4) Знаходимо $(S_{nm})_{кр} = K_{кр}$.
- 5) Якщо $(S_{nm})_{емп} < K_{кр}$, то висунуту гіпотезу приймаємо, в протилежному випадку – відхиляємо, як хибну.

Одновибірковий критерій погодженості Колмогорова

Нехай $x_1, \dots, x_n$ - вибірка з генеральної сукупності ξ . Потрібно перевірити гіпотезу про те, що випадкова змінна ξ керується неперервною функцією розподілу $F(x)$:

$$H_0: P\{\xi \leq x\} = F(x).$$

Методика перевірки цієї нульової гіпотези ґрунтується на висновку теореми Глівенка, згідно якої:

$P(\sup_{-\infty < x < \infty} |F_n(x) - F(x)| \rightarrow 0) = 1$, де $F_n(x)$ - емпірична функція розподілу.

На основі цієї вибірки знаходимо емпіричну функцію розподілу:

$$F_n(x) = \begin{cases} 0, & x < x_{(1)} \\ \frac{m_i}{n}, & x_{(i)} \leq x < x_{(i+1)}, \quad i = 1, \dots, n-1 \\ 1, & x_{(n)} \leq x, \end{cases}$$

де m_i - кількість елементів $x_{(k)}$ варіаційного ряду деякої вибірки, які не більші за x .

Розглянемо статистику: $D_n = \sup_{-\infty < x < \infty} |F_n(x) - F(x)|$.

Колмогоров довів, що статистика $K_n = \sqrt{n}D_n$ має розподіл незалежний від гіпотетичної функції розподілу $F(x)$, який при $n \rightarrow \infty$ збігається до розподілу:

$$K(x) = \begin{cases} 0, & x < 0 \\ \sum_{k=-\infty}^{+\infty} (-1)^k e^{-2x^2 k^2}, & x \geq 0 \end{cases}$$

Статистику $K_n = \sqrt{n}D_n$ називають статистикою Колмогорова.

Алгоритм критерію Колмогорова

- 1) Вибираємо рівень значущості α .
- 2) Будуємо варіаційний ряд даної вибірки.
- 3) Знаходимо значення гіпотетичної функції розподілу в точках варіаційного ряду та модулі різниць значень емпіричної функції у точках безмежно близьких зліва до точок цього ряду та гіпотетичної функції розподілу в точках варіаційного ряду.
- 4) Знаходимо емпіричне значення K_{emn} статистики Колмогорова як максимальне значення модулів таких різниць $D_n = \max(d^+, d^-)$,

де $d^+ = \max |F_n(x_i) - F(x_i)|$, $d^- = \max |F_n(x_i - 0) - F(x_i)|$.

- 5) При вибраному рівні значущості α , знаходимо критичне значення $K_{кр}$ статистики Колмогорова. Критичні значення статистики Колмогорова для найбільш уживаних рівнів значущості.

α	0,2	0,1	0,05	0,02	0,01	0.001
$K_{кр}$	1,073	1,224	1,358	1,520	1,627	1,950

- 6) Якщо $K_{emn} < K_{кр}$, то гіпотезу приймаємо, в протилежному випадку – відхиляємо, як хибну.

Завдання для аудиторної роботи

Завдання 1. Під час моніторингу безпеки мережі адміністратор аналізує часові інтервали (у мілісекундах) між надходженням зашифрованих пакетів даних. Для певних протоколів анонімізації трафіку важливо, щоб затримки були розподілені рівномірно — це допомагає запобігти атакам за сторонніми каналами, де злоумисник намагається вгадати тип контенту за таймінгами. Отримано вибірку незалежних спостережень за часом затримки x (мс):

8,95; 9,24; 9,18; 9,28; 9,33; 9,25; 9,06; 9,12; 9,35; 9,0.

Перевірити гіпотезу про те, що дана вибірка взята з генеральної сукупності, яка має рівномірний розподіл на проміжку $[8,9; 9,4]$.

Завдання 2. Команда SOC розслідує підозрілу активність у внутрішній мережі. Було виявлено автоматизований скрипт, який здійснює спроби аутентифікації на сервері. Для обходу систем виявлення ботів злоумисники часто намагаються імітувати рівномірні часові інтервали між запитами. Аналітик зафіксував часові інтервали (у секундах) між 10 послідовними запитами:

13,95; 14,18; 14,24; 14,25; 14,28; 14,33; 14,12; 14,06; 14,35; 14,00.

Необхідно перевірити статистичну гіпотезу про те, що інтервали між запитами підпорядковуються рівномірному розподілу на проміжку $[13,94; 14,38]$. Якщо гіпотеза підтвердиться, це може свідчити про роботу детермінованого алгоритму.

Завдання 3. Аналізується робота генератора випадкових чисел (ГВЧ), який використовується для створення сесійних ключів. Через фізичні особливості апаратного модуля, значення напруги в контурі мають коливатися навколо номіналу за нормальним законом. Згідно з технічною документацією, математичне сподівання напруги становить 9,8 мВ, а середньоквадратичне відхилення 0,025 мВ. Дані вимірювань:

9,74; 9,75; 9,75; 9,76; 9,77; 9,77; 9,77; 9,78; 9,78; 9,79; 9,79; 9,79; 9,79; 9,80; 9,80; 9,81; 9,81; 9,81; 9,82; 9,83.

Використовуючи критерій Колмогорова, перевірити гіпотезу про те, що дані відповідають нормальному закону розподілу.

Завдання 4. Адміністратор безпеки інформаційних систем аналізує інтервали часу (у хвиликах) між спробами авторизації в системі з однієї IP-адреси, щоб визначити, чи відповідає активність автоматизованому скрипту. Припускається, що інтервали між запитами підпорядковуються експонентному закону розподілу.

Маємо вибірку спостережень: **0,18; 0,56; 1,37; 2,46; 0,87**

Використовуючи одновибірковий критерій погодженості Колмогорова, перевірте нульову гіпотезу про те, що дана вибірка належить до генеральної сукупності з експонентним законом розподілу, параметр якого $\lambda = 1$.

Завдання 5. Адміністратор безпеки мережі порівнює два вузли проксі-сервера, щоб з'ясувати, чи ідентично вони обробляють трафік. Оцінюється час затримки (мс) при передачі критично важливих пакетів даних. Маємо дві вибірки незалежних спостережень затримки для вузлів А та В:

Вузол А : 0,95; 1,15; 1,24; 1,25; 1,33; 1,16; 1,31; 1,15; 1,27; 1,00

Вузол В: 0,90; 1,01; 1,24; 1,27; 1,34; 1,07; 1,27; 1,33; 0,98; 1,11

Використовуючи критерій Смирнова, перевірте нульову гіпотезу про те, що розподіли часу затримки на обох вузлах є однаковими.

Завдання 6. Офіцер безпеки аналізує рівень ентропії пакетів даних, що проходять через два різні вузли мережі протягом 16 сесій спостереження. Зафіксовано відхилення ентропійних показників від еталонного значення для двох сегментів мережі:

Сегмент А: -19,2; -14,8; -19,6; -11,1; -9,4; -16,9; -13,7; -4,9; -13,9; -9,4; -8,3; -7,9; -5,3; -9,4; -11; -13,0.

Сегмент В: -21,8; -15,4; -20,8; -11,3; -7,4; -11,6; -19,2; -11,3; -13,0; -7,4; -15,1; -11,3; -14,4; -11,1; -10,5; -7,2

Перевірити статистичну гіпотезу про те, що на формування обох вибірок впливають однакові системні чинники та конфігурації безпеки.

Завдання 7. Система моніторингу безпеки фіксує час відгуку (у секундах) сервера при спробах входу в систему. Порівнюються два набори даних: легітимні запити від довірених користувачів та підозрілі запити, що надходять із невідомої підмережі. Якщо розподіл часу відгуку для обох груп однаковий, це свідчить про нормальну роботу мережі. Якщо ж розподіли суттєво відрізняються, це може вказувати на спробу реалізації атаки за сторонніми каналами, де злоумисник намагається вгадати пароль, аналізуючи мікрозатримки сервера. Маємо дві вибірки часових інтервалів (у сек) для груп запитів Х та Y:

Група Х: 2,95; 1,25; 2,65; 1,74; 2,00; 1,65; 2,15; 1,25

Група Y: 1,15; 2,00; 1,29; 1,95; 2,05; 2,74; 1,85; 1,90; 2,65; 2,74

Використовуючи критерій Смирнова, перевірте нульову гіпотезу про те, що аномалій у часі обробки запитів не виявлено.

Завдання для самостійної роботи

Завдання 1. Під час тестування нового алгоритму шифрування проводиться аудит якості генератора випадкових чисел (ГВЧ), що відповідає за створення ініціалізуючих векторів. Згідно з вимогами безпеки, вихідні значення в діапазоні [1; 3] мають бути розподілені рівномірно. Якщо в розподілі з'являються "піки", це робить систему вразливою до передбачуваних атак. Отримали такі дані:

1,2; 1,3; 1,5; 1,8; 2,1; 2,3; 2,5; 2,6; 2,8; 2,9.

Використовуючи критерій Колмогорова, перевірити гіпотезу про те, що дані ГВЧ розподілені рівномірно на проміжку [1; 3].

Завдання 2. Під час передачі зашифрованих сигналів через супутниковий канал виникають амплітудні спотворення. Для коректної роботи декодера важливо, щоб ці спотворення (шум) мали нормальний розподіл з еталонними параметрами: математичне сподівання 10 та середньоквадратичне відхилення 0,05. Дані вимірювань:

10,05; 10,02; 10,12; 9,92; 9,98; 10,02; 9,96; 10,02; 9,96; 10,08; 9,95; 9,9; 10,0; 10,08; 9,95; 9,9.

Використовуючи критерій Колмогорова, перевірити гіпотезу про те, що амплітудні спотворення відповідають нормальному закону $N(10,0; 0,0025)$.

Завдання 3. Під час аудиту мережевої безпеки було зафіксовано 20 значень часових (у мілісекундах) між пакетами «heartbeat»-трафіку, що генерується прихованим каналом зв'язку. Отримали такі дані:

72.50, 72.43, 72.46, 72.32, 72.50, 72.56, 72.56, 72.32, 72.43, 72.38, 72.48, 72.48, 72.34, 72.54, 72.56, 72.56, 72.69, 72.46, 72.43, 72.41.

Перевірити гіпотезу про те, що затримки розподілені рівномірно на проміжку [72, 73]. Якщо розподіл рівномірний, це може свідчити про використання алгоритму маскуванню трафіку.

Завдання 4. У системі моніторингу безпеки аналізуються відхилення часу відповіді сервера від еталонного значення. Для стабільної системи ці відхилення мають відповідати стандартному нормальному розподілу (білий шум). Дані вимірювань відхилень у мс:

-0,65; -0,02; -0,30; 0,37; -0,01; -1,54; -1,53; -0,26; 0,44; 0,21; 0,27; 0,28; 1,00; 0,60; 1,25; 0,88; 1,43; -0,06; -0,81; -1,02; -0,86; 0,77; -0,17; 1,68; -1,17.

Використовуючи критерій Колмогорова, перевірити гіпотезу про те, що відхилення часу відповіді сервера розподілені за нормальним законом з математичним сподіванням 0 та середньоквадратичним відхиленням 1.

Завдання 5. Під час моніторингу мережевого вузла було зафіксовано 8 значень затримки пакетів (у мілісекундах) від підозрілого хоста. Потрібно з'ясувати, чи є ці затримки природними, чи вони генеруються програмним модулем, який намагається імітувати рівномірний шум у діапазоні [14.5; 15.5] мс, щоб приховати свій реальний "таймінговий відбиток". Отримали такі дані:

14.55; 14.82; 15.10; 14.71; 15.42; 14.98; 15.05; 15.38.

Перевірити гіпотезу про те, що затримка розподілена рівномірно на проміжку [14.5; 15.5].

Завдання 6. Під час тесту системи дистанційного керування було перехоплено 20 значень часових міток (у секундах від початку сесії), коли сервер генерував новий динамічний ключ доступу. Для захисту від атак типу «відгадування сесії», ці мітки мають бути рівномірно розподілені у часовому вікні [13.90; 14.40]. Отримали такі результати:

14.12; 13.95; 14.28; 14.12; 14.06; 14.35; 14.12; 14.00; 13.95; 14.24; 14.25; 14.28; 14.12; 14.06; 14.35; 14.24; 14.00; 14.12; 14.25; 14.28.

Перевірити гіпотезу про рівномірний розподіл значень на проміжку [13.90; 14.40].

Завдання 7. Під час моніторингу захищеного каналу зв'язку було виділено 25 значень амплітуди фоновому шуму (після стандартизації):

-0.85; 1.22; -0.15; 0.45; -1.60; 0.05; 0.98; -0.34; 0.22; -0.71; 0.55; 1.10; -1.05; -0.20; 0.38; 1.45; -0.62; 0.01; -1.15; 0.82; 0.27; -0.44; 0.61; -0.09; 1.30.

У нормальному стані системи цей шум повинен відповідати стандартному нормальному розподілу $N(0, 1)$. Якщо в каналі з'являється стороннє втручання або прихована передача даних, характеристики розподілу зміняться. Використовуючи критерій згоди Колмогорова,

перевірити гіпотезу про те, що генеральна сукупність, з якої взята вибірка, має нормальний розподіл $N(0, 1)$.

Завдання 8. В основі системи поведінкової біометрії лежить аналіз часу утримання клавіш користувачем. Для авторизованого адміністратора цей час (у мілісекундах, після стандартизації) має відповідати нормальному закону $N(0, 1)$. Якщо розподіл суттєво змінюється, система вважає, що за клавіатурою інша людина або бот. Використовуючи критерій Колмогорова, перевірити гіпотезу про те, що вибірка з 15 вимірювань відповідає стандартному нормальному розподілу. Отримано такі дані:

-1.55; -1.20; -0.85; -0.42; -0.30; -0.11; 0.01; 0.05; 0.18; 0.44; 0.52; 0.81; 1.05; 1.25; 1.40; 1.75.

Завдання 9. Аналітик центру моніторингу кібербезпеки (SOC) порівнює швидкість обробки мережових запитів двома різними версіями фільтра трафіку (**Фільтр А** та **Фільтр В**). Маємо дві вибірки незалежних спостережень часу обробки (у мілісекундах) для обох фільтрів:

Фільтр А: 1,22; 1,45; 1,30; 1,15; 1,50; 1,28; 1,42; 1,18; 1,35; 1,22; 1,40; 1,38

Фільтр В : 1,10; 1,25; 1,15; 1,32; 1,20; 1,28; 1,40; 1,12; 1,25; 1,30; 1,45; 1,38

Використовуючи критерій Смірнова, перевірте нульову гіпотезу про те, що розподіли часу обробки на обох фільтрах є однаковими.

Завдання 10. Аналітик з кібербезпеки порівнює інтенсивність використання системних ресурсів (навантаження на ЦП у %) двома ідентичними віртуальними машинами, на одній з яких встановлено оновлений патч безпеки. Необхідно з'ясувати, чи вплинуло оновлення на статистичний розподіл навантаження, чи обидві машини продовжують працювати згідно з єдиним законом розподілу. Маємо дві вибірки спостережень навантаження (у %) для обох машин:

Машина А : 12,5; 14,2; 11,8; 15,0; 13,4; 12,9; 14,8; 11,5; 13,1; 12,2; 14,0; 13,7; 12,8; 14,5

Машина В : 11,2; 12,8; 11,5; 13,0; 12,2; 12,5; 14,2; 11,0; 12,4; 13,1; 14,6; 13,9

Використовуючи критерій Смірнова, перевірте гіпотезу про те, що розподіли навантаження ідентичні.

Завдання 11. Адміністратор бази даних порівнює швидкість виконання SQL-запитів після впровадження нового методу індексації. Необхідно перевірити, чи змінився розподіл часу виконання запитів (у мілісекундах), що може вказувати на нестабільність роботи бази або наявність "вузьких місць" у новій конфігурації. Маємо дві вибірки часових інтервалів обробки для двох методів:

Метод А: 45, 52, 48, 60, 55, 47, 51, 58, 49, 53

Метод В : 42, 50, 44, 55, 48, 46, 52, 43, 47, 50, 49, 50

Використовуючи критерій Смірнова, перевірте нульову гіпотезу про те, що метод індексації не змінив характер розподілу часу.

Завдання 13. Система виявлення вторгнень (IDS) фіксує час між двома послідовними спробами підбору пароля до адміністративної панелі сайту. Маємо вибірку часу (у секундах):

0,42; 0,85; 2,10 ;1,12; 0,95; 2,30; 0,68; 1,55

Використовуючи одновибірковий критерій погодженості Колмогорова, перевірте нульову гіпотезу про те, що дана вибірка належить до генеральної сукупності з показниковим законом розподілу, параметр якого $\lambda = 0.8$. Рівень значущості 0,01.

Завдання 14. Відділ моніторингу аналізує кількість мережесих запитів за секунду, що надходять на два різні сервери балансування навантаження. Потрібно перевірити, чи ідентичний статистичний характер трафіку на обох серверах, щоб виключити можливість некоректного розподілу запитів алгоритмом балансування. Маємо дві вибірки спостережень:

Сервер А: 12, 15, 14, 12, 18, 20, 14, 15, 12, 16, 17, 14, 15, 19, 15, 18

Сервер В: 11, 14, 13, 15, 12, 14, 11, 13, 15, 16, 12, 14, 13, 17, 12, 15, 14, 13, 16, 11

Використовуючи двовибірковий критерій Смірнова, перевірте нульову гіпотезу про те, що розподіли кількості запитів на обох серверах однакові. Рівень значущості 0,02.

Завдання 15. Аналітик з кібербезпеки досліджує час (у секундах) між надходженням нових запитів на підключення до VPN-шлюзу. Маємо вибірку з 20 спостережень:

0.2, 0.5, 1.1, 0.5, 2.4, 3.8, 1.1, 0.2, 0.8, 4.5, 1.1, 2.4, 0.5, 1.9, 3.1, 0.8, 1.1, 0.2, 5.2, 2.4

Вважається, що для нормального фонових трафіку ці інтервали мають підпорядковуватися показниковому (експонентному) закону розподілу з параметром $\lambda = 0.5$. Використовуючи критерій погодженості Колмогорова, перевірте нульову гіпотезу про відповідність вибірки показниковому закону розподілу з $\lambda = 0.5$. Рівень значущості 0,02.

Критичні значення $\varepsilon_{\alpha;n}$ для верхньої межі модуля різниці теоретичної та емпіричної функцій розподілу (критерій Колмогорова)

n	Значення α			n	Значення α		
	0,05	0,02	0,01		0,05	0,02	0,01
1	0,9750	0,9900	0,9950	25	0,2640	0,2952	0,3166
2	0,8419	0,9000	0,9293	30	0,2417	0,2702	0,2899
3	0,7076	0,7846	0,8290	35	0,2243	0,2507	0,2690
4	0,6239	0,6889	0,7342	40	0,2101	0,2349	0,2520
5	0,5633	0,6272	0,6685	45	0,1984	0,2218	0,2380
6	0,5193	0,5774	0,6166	50	0,1884	0,2107	0,2260
7	0,4834	0,5384	0,5758	55	0,1798	0,2011	0,2157
8	0,4543	0,5065	0,5418	60	0,1723	0,1927	0,2067
9	0,4300	0,4796	0,5133	65	0,1657	0,1853	0,1988
10	0,4093	0,4566	0,4889	70	0,1598	0,1786	0,1917
11	0,3912	0,4367	0,4677	75	0,1544	0,1727	0,1853
12	0,3754	0,4192	0,4491	80	0,1496	0,1673	0,1795
13	0,3614	0,4036	0,4325	85	0,1452	0,1624	0,1742
14	0,3489	0,3897	0,4176	90	0,1412	0,1579	0,1694
15	0,3376	0,3771	0,4042	95	0,1375	0,1537	0,1649
20	0,2941	0,3287	0,3524	100	0,1340	0,1499	0,1608

При $n > 100$ слід користуватися асимптотичними границями

$$\varepsilon_{0,05;n} = \frac{1,36}{\sqrt{n}}; \quad \varepsilon_{0,01;n} = \frac{1,63}{\sqrt{n}},$$

для яких справжні коефіцієнти надійності навіть трохи більші від 0,95 і 0,99, відповідно.